



ANDRÉS PADRÓN QUINTANA

*RESUMEN: HOW COMPLEX IS YOUR CLASSIFICATION
PROBLEM? A SURVEY ON MEASURING
CLASSIFICATION COMPLEXITY*

Science and Machine Learning Applied to Financial
Markets – Módulo III.

Resumen del artículo *How complex is your classification problem? A survey on measuring classification complexity*

Alumno: Andrés Padrón Quintana

El artículo revisa de manera exhaustiva las medidas de complejidad de problemas de clasificación que pueden extraerse directamente de los datos de entrenamiento para estimar la dificultad de separar clases y, con ello, orientar el diseño de técnicas de preprocesamiento y aprendizaje supervisado. Parte de la premisa de que no existe un algoritmo universalmente superior para todos los problemas (no-free-lunch), por lo que entender las características geométricas y estadísticas del conjunto de datos ayuda a anticipar en qué escenarios cada técnica tiende a funcionar mejor o peor. El trabajo organiza el panorama en seis familias:

1. Medidas basadas en atributos que cuantifican solapamientos y poder discriminante univariado o direccional.
2. Linealidad que evalúa separabilidad por hiperplanos y su margen/errores
3. Vecindad que captura estructura local, puntos fronterizos y solapamiento mediante distancias, MST o “hiperesferas”
4. Redes (densidad, coeficiente de agrupamiento, hubs) a partir de un grafo ε -NN podado por etiquetas.
5. Dimensionalidad que refleja esparsidad con y sin PCA
6. Desbalance de clases. Todas se estandarizan a intervalos acotados donde valores mayores indican mayor complejidad, y se reportan costos asintóticos para su cálculo, destacando que muchas requieren matrices de distancias.

El artículo también presenta ECoL (Extended Complexity Library), un paquete de R disponible en CRAN y GitHub que implementa un conjunto de 22 medidas con definiciones normalizadas, límites e interpretación homogénea (más alto significa más complejo). Este paquete facilita reutilizar matrices de distancia y clasificadores lineales para computar varias métricas de manera eficiente.

En cuanto a usos, la literatura muestra aplicaciones en: (i) análisis de datos y generación de datasets sintéticos “controlados” por complejidad; (ii) preprocesamiento (selección de variables, selección de instancias, filtrado de ruido, y tratamiento del desbalance); (iii) algoritmos de aprendizaje (delimitación de dominios de competencia, ajuste de hiperparámetros y diseño de esquemas dinámicos de selección); y (iv) meta-learning (recomendación de modelos/estrategias según meta-características). El mensaje central es que combinar medidas complementarias da diagnósticos más robustos, y que aún hay oportunidades para integrar estos diagnósticos en el diseño de métodos.

Aplicación en el área laboral

En el contexto de mi tesina profesional para licenciatura de **riesgo de crédito minorista** con variable objetivo *Credit assignment*, el marco de complejidad permite **diseñar el pipeline** antes de modelar:

1. Diagnóstico inicial
 - Desbalance: C1 (entropía) y C2 (imbalance ratio) para cuantificar si la clase “No aprobado” está subrepresentada y estimar su severidad; esto orienta si aplicar *class weighting*, *resampling* o ajustar umbrales de decisión.
 - Separabilidad y solapamiento: L1–L2 (SVM lineal) para detectar linealidad aproximada; N1–N3 para medir frontera y errores 1-NN por *leave-one-out*; LSC para angostura del margen entre clases (útil si hay variables con umbrales regulatorios).
 - Esparsidad/colinealidad: T2–T4 (y PCA al 95%) para decidir si conviene reducir dimensionalidad o agrupar categorías
2. Acciones concretas guiadas por el diagnóstico
 - Si C2 alto y N1/N3 elevados (solapamiento + desbalance), priorizar recolección de más negativos “difíciles”, *SMOTE* conservador y métricas robustas (AUC-PR); ajustar umbral óptimo por costo regulatorio (Falsos Positivos).
 - Si L1/L2 bajos, iniciar con Regresión Logística (coeficientes interpretables) e inmunización por *shrinkage*; si L3/N4 altos, considerar árboles/ensembles o SVM no lineal.
 - Si T4 alto (muchas dimensiones relevantes) y F1/F3 pobres (poco poder univariado), usar interacciones/transformaciones y selección de variables guiada por mejora en N1–N3 y por validación cruzada.

Este enfoque ofrece trazabilidad y justificantes técnicos frente a auditoría/regulador, al ligar cada decisión de modelado a un indicador de complejidad medible.

Referencias

Lorena, A. C., Garcia, L. P. F., Lehmann, J., Souto, M. C. P., & Ho, T. K. (2021). *How complex is your classification problem? A survey on measuring classification complexity*. arXiv:1808.03591.