



Resumen: A protocol for data exploration to avoid common statistical problems

Data Science and Machine Learning
Applied to Financial Markets – Módulo III.

ANDRES PADRON QUINTANA



Resumen del artículo *A protocol for data exploration to avoid common statistical problems*

Alumno: Andrés Padrón Quintana

El artículo de Zuur & Ieno propone un protocolo sistemático de exploración de datos para prevenir errores estadísticos frecuentes antes de modelar. Los autores destacan que una parte considerable de trabajos aplicados incurre en violaciones de supuestos (normalidad, homocedasticidad, independencia, colinealidad), lo que incrementa los errores tipo I/II y puede conducir a conclusiones equivocadas, especialmente en contextos aplicados donde se toman decisiones de gestión o política. Por ello, recomiendan una etapa explícita de “data exploration” previa al ajuste de modelos, separada de la contrastación de hipótesis y documentada con transparencia.

El protocolo recorre preguntas clave: (1) detección de atípicos en respuesta y covariables mediante boxplots y, preferentemente, Cleveland dotplots; enfatiza verificar errores de medición y la influencia real de observaciones extremas sobre parámetros/ajustes. (2) evaluación de ceros “en exceso” (zero inflation) en conteos, sugiriendo GLM inflados en ceros cuando corresponda; (3) revisión de normalidad solo si la técnica lo requiere y privilegiando herramientas gráficas sobre tests preliminares; (4) verificación de homogeneidad de varianza con residuales; (5) atención a interacciones y a desbalances muestrales; (6) comprobación de independencia temporal/espacial (p. ej., con ACF) y uso de estructuras apropiadas cuando hay dependencia; (7) tratamiento de colinealidad con VIF y visualizaciones (pares, correlaciones, PCA), priorizando la eliminación informada de covariables colineales.

El artículo subraya además buenas prácticas: documentar las decisiones de exploración, usar gráficos como primera línea de defensa, evitar transformaciones de la variable respuesta salvo necesidad (pues pueden alterar interpretaciones), y recordar que la exploración puede consumir hasta la mitad del tiempo analítico, pero reduce sustancialmente riesgos de inferencia. En síntesis, la exploración disciplinada mejora la calidad de modelos y recomendaciones al disminuir errores y sesgos derivados de supuestos incumplidos o patrones no detectados.

Conceptos clave

- **Atípicos (outliers) e influencia:** distinguir valores extremos reales de errores de medición; evaluar su impacto en parámetros antes de eliminarlos.
- **Zero inflation:** en conteos, ceros excesivos sesgan Poisson/NegBin si no se modelan explícitamente.
- **Normalidad y homocedasticidad:** comprobar solo si el método lo exige; usar residuales y gráficos; la regresión lineal es robusta a leves desviaciones.
- **Independencia:** la autocorrelación temporal/espacial viola supuestos; ajustar con estructuras adecuadas (p. ej., correlación/jerarquías).
- **Colinealidad:** infla errores estándar y oculta efectos; usar VIF, pares y PCA; eliminar variables redundantes de forma informada.

Metodología (protocolo de exploración)

1. **Explorar atípicos** en Y y X (boxplots, Cleveland dotplots) y confirmar en datos crudos;
2. **Ceros**: identificar cero-inflación y elegir familia/modelo apropiado;
3. **Normalidad**: verificar solo si aplica; privilegiar inspección gráfica;
4. **Heterocedasticidad**: revisar residuales vs. ajustados y considerar transformaciones técnicas (GLS) en lugar de transformar la respuesta por defecto;
5. **Interacciones y desbalance**: usar coplots y revisar tamaños muestrales por subgrupo;
6. **Independencia**: inspeccionar ACF/estructura espacial y, de ser necesario, modelarla;
7. **Colinealidad**: calcular VIF, usar pares/correlaciones/PCA y depurar X.

Aplicación en el área laboral

- **Scoring de crédito (PD) y originación:**
 - Antes de entrenar un logit/árbol/boosting, aplicar VIF y pares en *features* socioeconómicas/financieras (ingreso, antigüedad, saldo, líneas abiertas) para controlar colinealidad que oculta señales (p. ej., decidir entre “ingreso mensual” vs. “capacidad de pago” derivados).
 - Detectar atípicos (ingresos, utilización de crédito, antigüedad laboral) y confirmar en la fuente; diferenciar “fraude/anomalía” de “segmento legítimo” antes de excluir.
 - Si hay **desbalance** temporal o por segmento (p. ej., pocos rechazos en ciertos meses), evaluar interacciones/temporada con coplots y evitar conclusiones por submuestras pequeñas.
- **Modelos de severidad/frecuencia en seguros o fraude (conteos):**
 - En siniestros o eventos de fraude, revisar **cero-inflación** y considerar modelos inflados en ceros para evitar sesgos en parámetros y errores estándar.
- **Riesgo de mercado y *trading* cuantitativo:**
 - Comprobar **independencia**: los retornos/volatilidades presentan autocorrelación; usar ACF y estructuras temporales apropiadas o modelos de correlación para no inflar significancia en pruebas/regresiones.
- **Gobernanza del modelo (*model risk*):**
 - Documentar cada decisión de exploración (qué se eliminó por VIF, qué outliers se recodificaron y por qué), separando exploración de pruebas confirmatorias para cumplir con auditoría interna/regulatoria y asegurar reproducibilidad.

Referencias

Zuur, A. F., Ieno, E. N., & Elphick, C. S. (2010). A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, 1(1), 3–14. <https://doi.org/10.1111/j.2041-210X.2009.00001.x>