



Data Science and Machine Learning Applied to Financial
Markets – Módulo III.

RESUMEN: WEB SCRAPING TECHNIQUES AND APPLICATIONS: A LITERATURE REVIEW

ANDRES PADRON QUINTANA

ITAM



Resumen del artículo Web Scraping Techniques and Applications: A Literature Review

Alumno: Andrés Padrón Quintana

El artículo *Web Scraping Techniques and Applications: A Literature Review* presenta una revisión estructurada del estado del web scraping: conceptos clave, métodos, tecnologías y aplicaciones en múltiples dominios. El artículo inicia motivando el papel del scraping como vía esencial de recolección de datos en la era de big data —especialmente ante la abundancia de información en la web y la necesidad de extraer conocimiento útil para la toma de decisiones— y expone su objetivo: ofrecer una guía actualizada para investigadores y practicantes que buscan minar datos en línea de forma efectiva.

La metodología de la revisión se organiza en etapas: definición de preguntas de investigación (cómo recolectar datos desde Internet; qué es la extracción web y cómo realizarla; técnicas y aplicaciones), criterios de inclusión/exclusión (publicaciones hasta junio de 2021, pares ciegos, capítulos, reportes, etc.), desarrollo de una nomenclatura de búsqueda en bases como Scopus, Web of Science y Google Scholar con términos “web scraping/web data extraction/web mining/web crawling”, análisis independiente y mapeo de resultados, y síntesis por ejes (aplicaciones, métodos, tecnologías, y desarrollo de herramientas).

En aplicaciones, se documentan casos en salud, redes sociales/marketing (análisis de sentimiento, engagement, intención de compra), finanzas (indicadores de innovación a partir de textos corporativos, eventos financieros), investigación académica (citaciones y producción científica), y otros sectores (minerales, moda, silvicultura, seguridad vial).

En técnicas, se comparan estrategias como “copy & paste”, parsing HTML/DOM, expresiones regulares, XPath, anotación semántica y enfoques con visión por computadora; además, discute tecnologías como crawlers (en variantes focused, incremental, distributed, parallel, hidden), parsers especializados y políticas de crawling (selección, revisit, politeness, paralelización).

Respecto a herramientas, revisa ecosistemas en Python/Java/R (BeautifulSoup, Scrapy, Selenium, Jsoup, Apache Nutch, RCrawler), describe la arquitectura de Scrapy (engine, scheduler, downloader, spiders, pipelines, middlewares) y ofrece comparativos de desempeño/extensibilidad. La conclusión destaca a Scrapy por su rapidez (llamadas asíncronas), flexibilidad e integración con proxies/VPNs/CAPTCHAs, lo que lo hace idóneo para proyectos complejos.

2) Aplicación en el área laboral

En un contexto de análisis de riesgo crediticio y ciencia de datos en finanzas (tema de tesis de licenciatura), el web scraping permite construir y actualizar *datasets* externos que complementen fuentes internas (por ejemplo, para enriquecer modelos de *credit scoring* o monitoreo de portafolios). Tres líneas aplicables:

1. **Prospección y *early warning* de Pymes/individuos.** Recolectar señales públicas (sitios corporativos, portales sectoriales, notas de prensa) para inferir actividad, lanzamientos o shocks idiosincráticos que afecten probabilidad de incumplimiento de pago (PD). Un *pipeline* con Scrapy (spider(s) temáticos), reglas de *politeness* y *scheduling* incremental reduce costos de vigilancia y mejora la frescura de indicadores no financieros.
2. **Señales de mercado/marketing para riesgo y cobranza.** El seguimiento de reseñas, engagement y anuncios (cuando es legal y permitido por *robots.txt/ToS*) aporta *features* de comportamiento (p. ej., actividad/alcance de campañas) que correlacionan con liquidez o ventas de deudores, útil para ajustar límites de crédito o priorizar gestión de cobranza. El artículo documenta casos en marketing, redes sociales y análisis de sentimiento que pueden trasladarse al *risk analytics*.
3. **Inteligencia competitiva y *benchmarking*.** La extracción periódica de tasas, comisiones o características de productos en sitios públicos ayuda a estimar elasticidades y riesgos de *churn*; combinada con parsers/DOM/XPath y políticas de re-visita, habilita tableros ejecutivos para producto y riesgo.

En todos los casos, lo recomendable es: (i) elegir tecnología según objetivo (Scrapy para volumen/velocidad; Selenium cuando haya JavaScript intensivo), (ii) diseñar *pipelines* con *data validation* y *de-duplication*, (iii) respetar *robots.txt*, términos de uso y consideraciones legales/éticas; (iv) versionar el *crawler* y la data (p. ej., DVC) para auditoría, tal como resaltan experiencias de scraping académico y comparativos tecnológicos discutidos en el paper.

Referencias

Lotfi, C., Srinivasan, S., Ertz, M., & Latrous, I. (2021). **Web Scraping Techniques and Applications: A Literature Review.** In R. Pal & P. K. Shukla (Eds.), *SCRS Conference Proceedings on Intelligent Systems* (pp. 381–394). Computing & Intelligent Systems, SCRS. <https://doi.org/10.52458/978-93-91842-08-6-38>