

Tarea 3: Métodos Numéricos en Python

Alumno: Andrés Padrón Quintana

Curso: Data Science and Machine Learning Applied to Financial Markets - Módulo III

Fecha: 13 de octubre de 2025

BLOQUE 1 — BÁSICO

1. **Integración** de $e^{(-x^2)}$ en $[0, 1]$
Se calcula I con cuadratura adaptativa (`scipy.integrate.quad`) y se contrasta con la regla del trapecio compuesta (`numpy.trapz`).
 - $I_{\text{quad}} \approx 0.74682413$ $I_{\text{trapz}} \approx 0.74682407$ ($m=1000$)
 - $|I_{\text{quad}} - I_{\text{trapz}}| \approx 6.13 \times 10^{-8}$ quad coincide con la referencia dentro del error numérico; trapecios converge al refinar mallas.
2. **Interpolación cúbica** (`interp1d`) y $s(2.5)$
Datos: $\{(0,1), (1,2.7), (2,5.8), (3,6.6), (4,7.5)\}$.
Resultado: $s(2.5) \approx 6.4328125$, coherente con $5.8 < s(2.5) < 6.6$.
La interpolación cúbica es suave y pasa por todos los puntos.
3. **Ajuste polinómico de grado 2 (usando puntos del problema 2)**
Modelo: $p_2(x) = a x^2 + b x + c$.
Coefficientes (LS): $(a, b, c) = (-0.278571, 2.804286, 0.782857)$.
Evaluación: $p_2(2.5) \approx 6.0525$.
El ajuste no interpola todos los puntos (minimiza error global), por eso $p_2(2.5) \neq s(2.5)$.
4. **Interpolación polinómica completa (grado 4)**
Interpolador p_4 de grado 4 con coeficientes aproximados $(a, b, c, d, e) = (0.254167, -2.141667, 5.345833, -1.758333, 1.000000)$.
Comparación en $x=2.5$:
 - $p_4(2.5) \approx 6.4804688$
 - $s(2.5) \approx 6.4328125$
 - $|p_4(2.5) - s(2.5)| \approx 4.77 \times 10^{-2}$ p_4 interpola exactamente los cinco puntos, pero puede oscilar más que la cúbica (fenómeno de Runge).
5. **Raíces** de $x^3 - 6x^2 + 11x - 6$
Usando `numpy.roots` y Newton–Raphson (`scipy.optimize.newton`).
Resultados: raíces reales = $\{1, 2, 3\}$.
Newton converge rápido cuando la semilla cae en la cuenca adecuada

BLOQUE 2 — INTERMEDIO

- 1) **Área** de $\sin(x)$ en $[0, \pi]$
Calculamos la integral $I = \int_0^\pi \sin(x) dx$.
 $I_{\text{quad}} \approx 2.000000000000$; valor exacto = 2; error ≈ 0 .
Coincidencia a precisión de máquina.

2) Interpolación de $\cos(x)$ + ruido (lineal vs. cúbica)

$y_i = \cos(x_i) + \varepsilon_i$, con $\varepsilon_i \sim N(0, 0.1^2)$, $n=20$, x_i en $[0, 10]$.

La interpolación lineal sigue más el ruido local (menos suave); la cúbica suaviza entre nodos y respeta la forma de $\cos(x)$, aunque puede ondular ligeramente.

3) Ajuste polinómico de grado 3

Modelo: $p_3(x) = a x^3 + b x^2 + c x + d$.

Coeficientes: $(a, b, c, d) = (-0.025823, 0.380188, -1.498508, 1.267758)$.

Evaluación: $p_3(5) \approx 0.0521$.

Comentario: el cúbico capta la tendencia global de $\cos(x)$ pese al ruido; no interpola cada punto y puede desviarse en bordes. (Fig. B2-3)

4) Raíz de $\cos(x) - x$ (Newton propio vs. `scipy.newton`)

Ecuación: $h(x) = \cos(x) - x = 0$.

Resultados ($x_0 = 1$):

- Newton propio: $x^* \approx 0.739085133215$ (5 iteraciones).
 - `scipy.newton`: $x^* \approx 0.739085133215$.
- Comentario: $h'(x) = -\sin(x) - 1 \neq 0$ cerca de la raíz \Rightarrow convergencia rápida y estable. (Fig. B2-4)

5) Mínimo de $x^4 - 3x^3 + 2$

Óptimo (`minimize_scalar`): $x^* \approx 2.25$; $\varphi(x^*) \approx -6.542969$.

El punto marcado coincide con el valle principal en $[-1, 3]$.

6) Descenso de gradiente en $f(x) = (x - 3)^2 + 4$

Gradiente: $\nabla f(x) = 2(x - 3)$.

$x_{k+1} = x_k - \alpha \cdot 2(x_k - 3) = (1 - 2\alpha) x_k + 6\alpha$. Con $x_0 = 0$ y 20 iteraciones:

- $\alpha = 0.1 \rightarrow x_{20} \approx 2.965412$; $f(x_{20}) \approx 4.001196$ (convergencia estable y lenta).
 - $\alpha = 0.5 \rightarrow x_{20} = 3.000000$; $f(x_{20}) = 4.000000$ (llega en 1 paso)
 - $\alpha = 0.9 \rightarrow x_{20} \approx 2.965412$; $f(x_{20}) \approx 4.001196$ (convergencia oscilatoria)
- Mínimo teórico: $x^* = 3$; $f(x^*) = 4$.

Conclusiones

1. Cuadraturas adaptativas (`quad`) son muy precisas; reglas compuestas convergen al refinar.
2. En interpolación, la cúbica es más suave; el polinomio global de alto grado puede oscilar.
3. Los ajustes polinómicos modelan la tendencia y no interpolan cada punto.
4. Newton–Raphson es rápido si la derivada no se anula cerca de la raíz.
5. `minimize_scalar` es fiable para mínimos univariados.
6. En descenso de gradiente, la tasa α gobierna estabilidad/velocidad; para cuadráticas, $\alpha = 0.5$ es ideal.