

ITAM

DATA SCIENCE AND MACHINE LEARNING APPLIED TO FINANCIAL MARKETS¹

Modulo III

Tarea: Análisis de Datos en python

Objetivo:

El estudiante será capaz de aplicar herramientas de **Python** (pandas, numpy, matplotlib, seaborn, scikit-learn, proplexity, imbalanced-learn) para explorar, preprocesar y analizar un conjunto de datos crediticios, comprendiendo conceptos de análisis exploratorio, transformación de atributos, construcción de pipelines, análisis de complejidad y técnicas de remuestreo para tratar el desbalance de clases.

Dataset:

Se utilizará el conjunto de datos German Credit Data, el cual contiene información sobre clientes de un banco con variables demográficas, financieras y de historial crediticio. Cada instancia está clasificada como buen o mal riesgo crediticio.

Atributos principales para considerar:

- Edad
- Sexo
- Trabajo
- Vivienda
- Cuenta_Ahorro
- Cuenta_Corriente
- Monto_Credito
- Periodo_Meses
- Tipo
- Resultado (variable objetivo)

El dataset original contiene 1000 observaciones y 10 atributos

Instrucciones

Carga y análisis inicial de los datos (2 pts)

- Cargar el dataset en un DataFrame de pandas.
- Revisar la estructura general (dimensiones, tipos de variables, valores nulos, duplicados).
- Describir brevemente cada atributo.
- Conclusión: estado inicial del dataset y retos preliminares.

Partición de datos: Train/Test (1 pt)

- Dividir el dataset en conjunto de entrenamiento y prueba (ej. 70%-30%).
- Justificar la partición y explicar por qué es importante.

Análisis exploratorio de datos (EDA) (3 pts)

- En el conjunto de entrenamiento:
 - Graficar distribuciones de variables numéricas (edad, monto, periodo).
 - Graficar frecuencias de variables categóricas (sexo, vivienda, trabajo, tipo, cuentas).
 - Analizar correlaciones entre variables numéricas.
 - Identificar outliers y patrones relevantes.
- Conclusión: hallazgos relevantes sobre la población analizada.

Preprocesamiento de datos (3 pts)

- Construir un pipeline de preprocesamiento con scikit-learn que incluya:
 - Tratamiento de valores nulos (imputación).
 - Codificación de variables categóricas (One-Hot Encoding).
 - Escalamiento de variables numéricas (StandardScaler o MinMaxScaler).
- Justificar cada paso.

Análisis de complejidad con Proplexity (2 pts)

- Instalar y aplicar la librería proplexity.
- Calcular medidas de complejidad del dataset (ej. linealidad, solapamiento, dimensionalidad).
- Interpretar los resultados en el contexto del dataset crediticio.

Tratamiento del desbalance de clases (2 pts)

- Verificar el balance de la variable objetivo (buen/mal crédito).
- Aplicar técnicas de remuestreo (ej. SMOTE, RandomOverSampler o ADASYN).
- Mostrar la nueva distribución de clases.
- Conclusión: efecto del remuestreo en la representatividad de los datos.

Formato de Entrega

- Archivo principal: Jupyter Notebook (.ipynb) con todas las soluciones, comentarios y gráficas.
- PDF adjunto: Explicación breve de cada ejercicio, justificando los métodos usados y la interpretación de resultados.
- Nomenclatura de archivos:
 - **Proyecto_AnalisisDatos_NombreApellidoAA.ipynb**
 - **Proyecto_AnalisisDatos_NombreApellidoAA.pdf**

Entrega: por correo en una carpeta comprimida .zip con ambos archivos, a más tardar el 17/10/2025 a las 12:00 a.m.