

Tarea 4: Análisis de Datos en Python

Alumno: Andrés Padrón Quintana

Curso: DATA SCIENCE AND MACHINE LEARNING APPLIED TO FINANCIAL MARKETS.
Módulo III

Fecha: 17 de octubre de 2025

Contexto y datos

Se utiliza el dataset proporcionado **German Credit Data** (1,000 observaciones y 10 atributos) con variables demográficas/financieras y variable Resultado (buen/mal crédito). Atributos principales: Edad, Sexo, Trabajo, Vivienda, Cuenta_Ahorro, Cuenta_Corriente, Monto_Credito, Periodo_Meses, Tipo, Resultado.

1) Carga y análisis inicial

Hallazgos

- Dimensiones: (1000, 10).
- Numéricas: Edad, Monto_Credito, Periodo_Meses.
- Categóricas: Sexo, Trabajo, Vivienda, Cuenta_Ahorro, Cuenta_Corriente, Tipo.
- Faltantes: Cuenta_Ahorro 183 (18.3%), Cuenta_Corriente 394 (39.4%).
- Duplicados: 0.

Decisiones y justificación

- Imputamos categóricas con categoría explícita “Desconocido” para preservar la señal del *missing* (que puede ser informativa).
- Imputamos variables numéricas con mediana por robustez ante outliers.
- Tratamos Sexo como categórica binaria aun si aparece 0/1.

Conclusión: dataset limpio de duplicados; faltantes concentrados en cuentas bancarias, que se tratarán con una categoría explícita. Esto evita eliminar filas y mantiene información.

2) Partición Train/Test (70/30, estratificada)

Resultados

- **Tamaños:** X_train (700, 9) y X_test (300, 9).
- **Proporción Resultado=1 (mal):** Total 0.70; Train 0.70; Test 0.70.

Justificación

- Estratificación para conservar la mezcla de clases en ambos conjuntos y obtener métricas más estables.
- random_state fijo para reproducibilidad.
- No se toca el set de prueba hasta la evaluación final.

3) EDA (sobre Train)

Numéricas

- Edad: media 35.40, mediana 33 (20–75).
- Monto_Credito: mediana 2,290; máximo 18,424 → clara asimetría a la derecha y outliers altos.
- Periodo_Meses: mediana 18, con picos en 12/18/24/36 (plazos estándar).

Por clase (medias)

- Resultado=0 (buen): Edad 33.68, Monto 3,932.75, Plazo 25.10.
- Resultado=1 (mal): Edad 36.14, Monto 2,937.57, Plazo 19.31.

Lectura

- Los buenos piden montos/plazos mayores (posible mejor solvencia); los malos son ligeramente mayores en edad.

4) Preprocesamiento (Pipeline)

Pasos

1. Imputación: mediana (numéricas) y “Desconocido” (categóricas).
2. Codificación: One-Hot Encoding a todas las categóricas (incluida Sexo), con `handle_unknown="ignore"` para robustez.
3. Escalamiento: `StandardScaler` en numéricas.

Resultado

- `X_train` → (700, 29), `X_test` → (300, 29). Total 29 features.

Justificación

- OHE transforma categorías a variables binarias sin imponer orden.
- Escalamiento estabiliza modelos lineales y métodos basados en distancia.
- Ajuste del pipeline solo con Train para evitar *leakage*.

5) Complejidad del conjunto (Problexity)

Métricas clave (train preprocesado)

- Estructura/densidad: `density=0.995`, `lsc=0.993`, `hubs=0.957` → datos densos y clusterizados con hubs.
- Señal en features: `f3=0.984`, `f4=0.969`, `f1=0.820` → existe información útil no trivial.
- Fronteras: `t1=0.731`, `t4=0.552`, `clsCoef=0.698` → fronteras irregulares y separabilidad moderada.
- Solapamiento/linealidad: `n2=0.420`, `n3=0.333` (solapamiento moderado) y `l1=0.088`, `l2=0.259`, `l3=0.219` (baja linealidad).

Implicación

- Una Regresión Logística es buena línea base, pero se esperan mejoras con métodos no lineales (árboles/ensambles) y ajuste de umbral según la métrica objetivo.

6) Desbalance de clases (SMOTE)

Antes (Train): mal = 490 (0.70), buen = 210 (0.30).

Después de SMOTE (Train): mal = 490 (0.50), buen = 490 (0.50).

Shapes: (700, 29) → (980, 29).

Justificación

- SMOTE sintetiza ejemplos de la minoritaria en el *feature space* ya transformado, reduciendo sesgo hacia la mayoritaria.
- Solo en Train (nunca en Test) para evitar *leakage*.
- Beneficia recall de la clase minoritaria; se recomienda evaluar también PR-AUC y F1.

Conclusión general

El flujo (EDA, preprocesamiento, análisis de complejidad, SMOTE, modelo) deja un set de 29 variables preparado para clasificación binaria. La complejidad sugiere fronteras no estrictamente lineales y solapamiento moderado; por ello, además del modelo lineal de referencia, conviene explorar ensambles (Random Forest, XGBoost) con validación cruzada estratificada y selección de umbral según la métrica objetivo del negocio.