

Series de tiempo

Introducción


Una serie de tiempo es una colección de observaciones realizadas de forma secuencial a lo largo del tiempo. Si solamente observamos una característica, los registros pertenecen a una serie *univariada*. Si recolectamos los valores de varias características, estaremos ante una serie de tiempo *multivariada*. Por lo general, las observaciones de una serie se realizan a intervalos iguales (equidistantes) a lo largo del tiempo, pero también es posible que los intervalos no sean equidistantes, condición que complica sobremanera su análisis estadístico.

Una característica muy importante propia de las series de tiempo es que, generalmente, hay dependencia entre observaciones adyacentes. La naturaleza de esta dependencia entre las observaciones, es de gran interés práctico. *El análisis de series de tiempo* consiste en el uso de técnicas estadísticas para analizar esta dependencia, y requiere el desarrollo de modelos estocásticos y dinámicos para el modelado de datos de series de tiempo, que son de uso común en múltiples áreas del quehacer humano.


Ejemplos reales de series de tiempo

- IPC, PIB, inflación, precio del petróleo, precio de una acción bursátil, precipitación pluvial, niveles diarios de algún contaminante, nivel de exportaciones de un país, número de robos diarios, consumo de un producto, nivel de agua de un río o presa, y un larguísimo etc., etc., etc.


Serie de tiempo nacimientos mensuales en NYC: 1946–1959




Registro de temperatura







Monthly totals of international airline passengers between 1949 to 1960





Diversas series de tiempo



- **Series de tiempo discretas.** Una serie de tiempo se considera *discreta* cuando las observaciones se toman en un conjunto de tiempos discretos, generalmente, igualmente espaciados. El término “discreta” se usa para series con esta característica, no obstante que la variable

medida sea continua.

- **Series de tiempo continuas.** Una serie de tiempo se considera *continua* cuando las observaciones se hacen de manera continua a lo largo de un intervalo de tiempo. El adjetivo “continua” se usa para este tipo de series, no obstante que la variable medida sólo tome valores en un conjunto discreto.

Objetivos del análisis de series de tiempo

- Descripción de los datos
- Interpretación de los datos
- Pronóstico (Uno de los objetivos usualmente más importantes)
- Control
- Modelación / Pruebas de hipótesis

Conceptos asociados a una serie de tiempo

Sea $\{X_t, t = 0, \pm 1, \pm 2, \dots\}$ una serie de tiempo.



- **La función media de X_t** , se define como

$$\mu_X(t) = \mathbb{E}(X_t)$$

- **La función de covarianza o de autocovarianza de X_t** , se define como

$$\gamma_X(r, s) = \text{Cov}_X(X_r, X_t) = \mathbb{E}[(X_r - \mu_r)(X_s - \mu_s)]$$

- **Estacionariedad:** Hablando vagamente, una serie de tiempo $\{X_t, t = 0, \pm 1, \pm 2, \dots\}$ se dice que es *estacionaria*, si no tiene cambios sistemáticos en la media (no hay tendencia de la serie), si no tiene cambios sistemáticos en la varianza (la varianza es constante a lo largo del tiempo) y si no hay variaciones periódicas (no tiene ciclos). En otras palabras, las características de un segmento de los datos, son similares a las de cualquier otro segmento. Mucha de la teoría de series de tiempo es sobre series estacionarias, por esta razón el análisis de series de tiempo algunas veces requiere de transformaciones de series no estacionarias a estacionarias, para hacer uso de esta teoría.



- **Estacionariedad estricta:** Una serie de tiempo $\{X_t, t = 0, \pm 1, \pm 2, \dots\}$ se dice que es *estrictamente estacionaria* o *fuertemente estacionaria*, si la distribución conjunta de $X_1, X_2, \dots, X_k$ es la misma que $X_{1+\tau}, X_{2+\tau}, \dots, X_{k+\tau}$ para todo entero $k > 0$, $\tau > 0$. En otras palabras, si las distribuciones conjuntas son invariantes a cambios de tiempo.

Esta propiedad es complicada de verificar, por lo que no es usual en la práctica. Una manera más simple y útil es caracterizar una serie a través de sus *momentos*, en particular, los dos primeros.

- **Estacionariedad débil:** Una serie de tiempo $\{X_t, t = 0, \pm 1, \pm 2, \dots\}$ se dice que es *débilmente estacionaria* o *estacionaria de segundo orden* si

- $\mu_X(t)$ es independiente de t (Fluctúa alrededor de un nivel fijo, $\mu_X(t)$).
- $\gamma_X(\tau) = \gamma_X(t + \tau, t)$ es independiente de t

esto significa que media y varianza son constantes y la función de *autocovarianza* sólo depende del *retrazo* (lag) de la serie, i.e., la dependencia de una observación respecto a observaciones pasadas depende únicamente de su rezago (la distancia entre dichas observaciones).

- Estrictamente estacionaria $\Rightarrow$ Débilmente estacionaria

- Si $X_1, X_2, \dots, X_n$ es *normal multivariada* $\forall i = 1, \dots, n$ y $\forall n > 0$, entonces Débilmente estacionaria $\Rightarrow$ Estrictamente estacionaria

- **Función de correlación o de autocorrelación**

Los valores de la función de autocovarianza dependen de las unidades de X_t , por lo que es más conveniente considerar la *función de autocorrelación* definida como

$$\rho_X(\tau) = \frac{\gamma_X(\tau)}{\gamma_X(0)}$$

con $\gamma_X(0) = \sigma_X^2$, la varianza de la serie.

Propiedades de la función de autocorrelación

- $\rho_X(0) = 1$
- $\rho_X(\tau) = \rho_X(-\tau)$
- $|\rho(\tau)| \leq 1$

Estimación de las funciones asociadas a una serie de tiempo

Estimación de los coeficientes de autocorrelación

Dadas las observaciones de una serie de tiempo X_t , la estimación de los coeficientes de autocorrelación son

$$r_k = \frac{\sum_{t=1}^{n-k} (X_t - \bar{X})(X_{t+k} - \bar{X}) / (n-k)}{\sum_{t=1}^n (X_t - \bar{X})^2 / n}, \quad k = 1, 2, \dots$$

con la correspondiente estimación de los coeficientes de autocovarianza dados por


$$c_k = \frac{1}{n-k} \sum_{t=1}^{n-k} (X_t - \bar{X})(X_{t+k} - \bar{X})$$

El correlograma

Una interpretación usual del conjunto de coeficientes de autocorrelación se hace a través del *correlograma*, en el que se grafican los coeficientes estimados r_k vs. su correspondiente retraso k , $k=0,1,2,\dots,M$, con M usualmente mucho menor que n . Por supuesto, r_0 es *uno*, ya que es la correlación de la serie con ella misma. Una inspección visual del correlograma puede ser útil para apreciar el grado de asociación que guarda una observación con sus adyacentes, además de su orden (cuántas observaciones atrás se tiene una correlación importante). También ayuda a percibir si la serie tiene ciclos. Para determinar cuántos coeficientes de correlación pueden considerarse importantes, es necesario realizar las pruebas de hipótesis correspondientes

$$\mathbb{H}_0 : \rho_k = 0 \quad vs. \quad \mathbb{H}_a : \rho_k \neq 0$$


La forma usual de saber qué correlaciones son estadísticamente significativas, es graficar las bandas de confianza en el correlograma. Las correlaciones que sobrepasen estas bandas, se considerarán significativamente distintas de cero.



El correlograma con correlaciones parciales

En muchas ocasiones la correlación entre dos variables se debe a que están correlacionadas con una tercera y no necesariamente entre sí. La correlación parcial es una medida de asociación que remueve la correlación que puede existir entre las variables de interés con otras variables coleccionadas, para mostrar sólo la correlación entre estas variables, sin considerar la que tienen con el resto del conjunto. El correlograma con correlaciones parciales es útil para determinar el orden de la serie de tiempo considerada.

Correlograma correlaciones parciales: serie de nacimientos en NYC



No unicidad de la funciones de autocovarianza y autocorrelación. Las funciones de autocovarianza y de autocorrelación, son herramientas muy útiles en la identificación del proceso estocástico subyacente a una serie de tiempo; sin embargo, estas funciones no identifican de manera única a este proceso. Aunque un proceso estocástico dado tiene una única estructura de covarianza (correlación), el reverso *no es cierto* en general. Por ejemplo, es posible encontrar muchos procesos normales y no normales con la misma función de autocorrelación, lo que genera dificultades para interpretar la correspondiente función de autocorrelación muestral y, por lo tanto, reconocer el proceso estocástico subyacente.

Algunas operadores aplicables a las series de tiempo

- **Operador de retraso:** Definimos el operador de retraso $\mathbf{B}$, como

$$\mathbf{B}^j X_t = X_{t-j} \quad \forall j \in \mathbb{Z}$$

- **Operador diferencia:** Definimos el operador diferencia ∇ , como

$$\nabla X_t = X_t - X_{t-1} = (1 - \mathbf{B})X_t$$

Series de tiempo vistas como procesos estocásticos

La idea de usar modelos matemáticos para describir las características de un fenómeno físico, es muy común. Algunas veces es posible derivar un modelo con base en alguna ley física, que permite calcular el valor de alguna característica, casi de forma exacta en algún instante de tiempo. Este cálculo es posible, si el modelo es enteramente determinista.

Probablemente el fenómeno físico no sea totalmente determinista porque, por ejemplo, desconocemos algunos factores que pueden afectarlo a lo largo del tiempo. En estos casos, es posible derivar modelos que puedan utilizarse para calcular la probabilidad de que un valor *futuro* esté entre algunos límites específicos. Tales modelos se conocen como modelos de probabilidad o modelos estocásticos. Entonces, una serie de tiempo $X_1, X_2, \dots, X_n$ de n observaciones sucesivas, se puede ver como una *realización muestral* de una población infinita de tales series de tiempo, que han sido generadas por el proceso estocástico subyacente.

Modelos comunes para series de tiempo

Existen varios procesos estocásticos que pueden ser apropiados como modelos para una serie de tiempo.

Proceso puramente aleatorio




Un proceso a *tiempo discreto* es *puramente aleatorio* si consiste en una secuencia de variables aleatorias, $\{X_t\}$, que son mutuamente independientes e idénticamente distribuidas. Generalmente asumimos que las variables tienen distribución normal con media *cero* y varianza σ_X^2 . Estas características implican que el proceso tiene media y varianza constante. Además, el supuesto de independencia significa que

$$\gamma(\tau) = \mathbb{Cov}(X_t, X_{t+\tau}) = \begin{cases} \sigma_X^2, & \text{si } \tau = 0 \\ 0, & \text{si } \tau = \pm 1, \pm 2, \dots \end{cases}$$

que significa que no existe correlación entre los diferentes valores de la serie, y la función de autocorrelación está dada por

$$\rho(\tau) = \mathbb{Cor}(X_t, X_{t+\tau}) = \begin{cases} 1, & \text{si } \tau = 0 \\ 0, & \text{si } \tau = \pm 1, \pm 2, \dots \end{cases}$$

ya que la media y la función de autocorrelación no dependen del tiempo, el proceso es *estacionario de segundo orden*. De hecho, el supuesto de independencia implica que es estrictamente estacionario. Los procesos puramente aleatorios son útiles en muchas situaciones, particularmente para construir procesos más complejos. Los procesos puramente aleatorios reciben también el nombre de *ruido blanco*, especialmente en ingeniería.



Caminata aleatoria

Suponga que $\{Z_t\}$ es un proceso a tiempo discreto, puramente aleatorio con media *cero* y varianza σ_Z^2 . Un proceso X_t se dice que es una *caminata aleatoria*, si

$$X_t = X_{t-1} + Z_t, \quad X_0 = 0 \Rightarrow X_1 = Z_1 \text{ y}$$

$$X_t = \sum_{i=1}^t Z_i$$


Entonces $\mathbb{E}(X_t) = t\mu$ y $\text{Var}(X_t) = t\sigma_Z^2$, por lo tanto, este proceso *no es estacionario*. No obstante, es interesante notar que el proceso dado por las diferencias

$$\nabla X_t = X_t - X_{t-1} = Z_t$$


sí es estacionario.

Ejemplos que pueden ser modelados a través de una caminata aleatoria, son fenómenos cuyo valor actual depende del valor inmediato anterior más alguna perturbación aleatoria. Por ejemplo, los precios diarios de algún insumo.


Caminata aleatoria




Caminata aleatoria



Autocorrelograma



Autocorrelograma parcial



Proceso de medias móviles

Suponga que $\{Z_t\}$ es un proceso puramente aleatorio con media *cero* y varianza σ_Z^2 . Un proceso X_t se dice que es un *proceso de medias móviles de orden q* (denotado como MA(q)), si

$$X_t = \beta_0 Z_t + \beta_1 Z_{t-1} + \cdots + \beta_q Z_{t-q}$$


con $\{\beta_i\}$ constantes. Las Z' s, usualmente se escalan para tener $\beta_0 = 1$. De esta definición se desprende que

$$\begin{aligned} \mathbb{E}(X_t) &= 0 \\ \text{Var}(X_t) &= \sigma_Z^2 \sum_{i=0}^q \beta_i^2 \\ \gamma(\tau) &= \begin{cases} 0, & \text{si } \tau > q \\ \sigma_Z^2 \sum_{i=0}^{q-\tau} \beta_i \beta_{i+\tau}, & \text{si } \tau = 0, 1, \dots, q \\ \gamma(-\tau) & \text{si } \tau < 0 \end{cases} \end{aligned}$$

Como $\gamma(k)$ no depende de t , y además la media es constante, el proceso es estacionario de segundo orden. Si las Z' s se distribuyen normal, entonces las X' s también lo son, y tenemos un proceso normal estrictamente estacionario. La función de autocorrelación del modelo MA(q) está dada por

$$\rho(\tau) = \begin{cases} 1, & \text{si } \tau = 0 \\ \frac{\sum_{i=0}^{q-\tau} \beta_i \beta_{i+\tau}}{\sum_{i=0}^q \beta_i^2}, & \text{si } \tau = 0, 1, \dots, q \\ 0, & \text{si } \tau > q \\ \rho(-\tau) & \text{si } \tau < 0 \end{cases}$$

No es necesario hacer ninguna restricción de las $\{\beta_i\}$ para un modelo MA de orden finito, pero generalmente es deseable imponer restricciones sobre estos coeficientes para asegurar que el proceso satisface la condición llamada *invertibilidad*, condición que discutiremos posteriormente.



Procesos autorregresivos

Suponga que $\{Z_t\}$ es un proceso puramente aleatorio con media *cero* y varianza σ_Z^2 . Un proceso X_t se dice que es un *proceso autorregresivo de orden p* (denotado como $\text{AR}(p)$), si

$$X_t = \alpha_1 X_{t-1} + \alpha_2 X_{t-2} + \cdots + \alpha_p X_{t-p} + Z_t$$

similar al modelo de regresión lineal múltiple, sólo que X_t tiene como regresores valores anteriores de ella misma, y no variables de otra naturaleza. Esto explica el prefijo *auto*.

Para deducir las características de este proceso, consideremos el modelo $\text{AR}(1)$, también conocido como *proceso de Markov*.

$$X_t = \alpha X_{t-1} + Z_t$$

Si realizamos sustituciones sucesivas en la expresión anterior, tenemos

$$\begin{aligned} X_t &= \alpha(\alpha X_{t-2} + Z_{t-1}) + Z_t \\ &= \alpha^2(\alpha X_{t-3} + Z_{t-2}) + \alpha Z_{t-1} + Z_t \end{aligned}$$

que, eventualmente, puede escribirse como un proceso de medias móviles de orden infinito, de la forma

$$X_t = Z_t + \alpha Z_{t-1} + \alpha^2 Z_{t-2} + \cdots$$

con $-1 < \alpha < 1$ para garantizar que la suma converge.

La posibilidad de que un proceso *AR* pueda escribirse como un *MA* y viceversa, significa que existe una dualidad entre procesos *AR* y *MA*, que es útil para diversos propósitos. En lugar de las sustituciones sucesivas, podemos utilizar el operador de retraso **B**. Entonces, podemos escribir el $\text{AR}(1)$ como

$$(1 - \alpha \mathbf{B})X_t = Z_t$$

de donde tenemos que

$$\begin{aligned}
X_t &= \frac{Z_t}{(1 - \alpha \mathbf{B})} \\
&= (1 + \alpha \mathbf{B} + \alpha^2 \mathbf{B}^2 + \cdots) Z_t \\
&= Z_t + \alpha Z_{t-1} + \alpha^2 Z_{t-2} + \cdots
\end{aligned}$$

Dada esta expresión es claro que

$$\begin{aligned}
\mathbb{E}(X_t) &= 0 \\
\mathbb{V}ar(X_t) &= \sigma_Z^2 (1 + \alpha^2 + \alpha^4 + \cdots)
\end{aligned}$$

Entonces, la varianza será finita, si $|\alpha| < 1$, en cuyo caso

$$\sigma_X^2 = \mathbb{V}ar(X_t) = \frac{\sigma_Z^2}{1 - \alpha^2}$$

La función de autocovarianza está dada por


$$\begin{aligned}
\gamma(\tau) &= \mathbb{E}[X_t X_{t+\tau}] \\
&= \mathbb{E} \left[\left(\sum_{i=0}^{\infty} \alpha^i Z_{t-i} \right) \left(\sum_{j=0}^{\infty} \alpha^j Z_{t+\tau-j} \right) \right] \\
&= \sigma_Z^2 \sum_{i=0}^{\infty} \alpha^i \alpha^{\tau+i} \quad \text{para } \tau \geq 0 \\
&= \frac{\alpha^\tau \sigma_Z^2}{(1 - \alpha^2)} \quad \text{para } |\alpha| < 1 \\
&= \alpha^\tau \sigma_X^2
\end{aligned}$$

para $\tau < 0$, tenemos $\gamma(\tau) = \gamma(-\tau)$. Como $\gamma(\tau)$, no depende de t , un AR(1) es estacionario de segundo orden, si $|\alpha| < 1$, y su función de autocorrelación está dada por

$$\rho(\tau) = \alpha^\tau \quad \tau = 0, 1, 2, \dots$$

que es una *función par*, entonces

$$\rho(\tau) = \alpha^{|\tau|}$$



Doble representación de un AR(1)

Representamos el proceso AR(1) de dos maneras, a saber

$$(1 - \alpha \mathbf{B})X_t = \phi(\mathbf{B})X_t = Z_t \text{ y}$$

$$X_t = \frac{Z_t}{(1 - \alpha \mathbf{B})} = \psi(\mathbf{B})Z_t$$

con $\psi(\mathbf{B}) = 1 + \alpha \mathbf{B} + \alpha^2 \mathbf{B}^2 + \dots$

En el caso general de un proceso $AR(p)$, de la misma forma como se hizo para el $AR(1)$, se puede escribir como un proceso de medias móviles de orden infinito, a través de las sustituciones sucesivas, o, más fácil, utilizando el operador de retraso.

$$\begin{aligned} X_t &= \alpha_1 \mathbf{B}X_t + \alpha_2 \mathbf{B}^2 X_t + \cdots + \alpha_p \mathbf{B}^p X_t + Z_t \\ \Rightarrow (1 - \alpha_1 \mathbf{B} - \alpha_2 \mathbf{B}^2 - \cdots - \alpha_p \mathbf{B}^p) X_t &= Z_t \end{aligned}$$

Entonces, al igual que el $AR(1)$, un $AR(p)$ puede escribirse de las formas

$$\begin{aligned} \phi(\mathbf{B})X_t &= Z_t \text{ y} \\ X_t &= \psi(\mathbf{B})Z_t \end{aligned}$$

con $\phi(\mathbf{B})$ un polinomio de orden p en $\mathbf{B}$, dado por

$$\phi(\mathbf{B}) = 1 - \alpha_1 \mathbf{B} - \alpha_2 \mathbf{B}^2 - \cdots - \alpha_p \mathbf{B}^p$$

y

$$\psi(\mathbf{B}) = \psi_0 + \psi_1 \mathbf{B} + \psi_2 \mathbf{B}^2 + \cdots$$

En el caso del $AR(1)$ la relación entre los coeficientes de estas dos expresiones del proceso, fue que los coeficientes de $\psi(\mathbf{B})$ resultaron potencias del coeficiente α en $\phi(\mathbf{B})$. Pero no es claro cómo se da, en general, la relación entre los coeficientes de ambas expresiones.

Ejemplo simple: $AR(2)$

Consideremos el modelo $AR(2)$, dado por

$$X_t = 1.3X_{t-1} - 0.4X_{t-2} + Z_t$$

entonces $\phi(\mathbf{B}) = 1 - 1.3\mathbf{B} + 0.4\mathbf{B}^2$. Nos preguntamos si es posible tratar la parte derecha de $\phi(\mathbf{B})$ como si se tratara de un $AR(1)$ para obtener la relación entre las representaciones. Sabemos que el modelo se puede escribir además como

$$X_t = \frac{Z_t}{1 - 1.3\mathbf{B} + 0.4\mathbf{B}^2}$$

Si factorizamos el polinomio de segundo orden en $\mathbf{B}$, tenemos

$$\begin{aligned}\phi(\mathbf{B}) &= 1 - 1.3\mathbf{B} + 0.4\mathbf{B}^2 \\ &= (1 - 0.5\mathbf{B})(1 - 0.8\mathbf{B})\end{aligned}$$

note que las raíces de $\phi(\mathbf{B})$, son los inversos de los coeficientes de $\mathbf{B}$ en la factorización del polinomio. Podemos ver que




$$\frac{1}{1 - 1.3\mathbf{B} + 0.4\mathbf{B}^2} = \frac{-\frac{5}{3}}{1 - 0.5\mathbf{B}} + \frac{\frac{8}{3}}{1 - 0.8\mathbf{B}}$$

entonces

$$\begin{aligned}X_t &= \left(\frac{-\frac{5}{3}}{1 - 0.5\mathbf{B}} + \frac{\frac{8}{3}}{1 - 0.8\mathbf{B}} \right) Z_t \\ &= \sum_{i=0}^{\infty} \left(-\frac{5}{3}(0.5)^i + \frac{8}{3}(0.8)^i \right) Z_{t-i}\end{aligned}$$

entonces, concluimos que para la representación en términos de $\psi(\mathbf{B})$

$$\psi_k = \left(-\frac{5}{3}(0.5)^k + \frac{8}{3}(0.8)^k \right)$$



¿Y para un AR(p) en general?

Supongamos que X_t es AR(p). Entonces

$$X_t = \psi(\mathbf{B})Z_t$$

y además como $\phi(\mathbf{B})X_t = Z_t$, tenemos

$$\phi(\mathbf{B})X_t = Z_t = \phi(\mathbf{B})\psi(\mathbf{B})Z_t$$

entonces

$$\phi(\mathbf{B})\psi(\mathbf{B}) = 1$$

equivalentemente

$$\phi(\mathbf{B})\psi(\mathbf{B}) = 1 + 0\mathbf{B} + 0\mathbf{B}^2 + 0\mathbf{B}^3 + \dots$$

es decir

$$(1 - \phi_1\mathbf{B} - \phi_2\mathbf{B}^2 - \dots - \alpha_p\mathbf{B}^p)(\psi_0 + \psi_1\mathbf{B} + \psi_2\mathbf{B}^2 + \dots) = 1 + 0\mathbf{B} + 0\mathbf{B}^2 + 0\mathbf{B}^3 + \dots$$

Igualando los coeficientes de ambos desarrollos, tenemos

$$\psi_0 = 1$$

para los coeficientes asociados a $\mathbf{B} = \mathbf{B}^1$, tenemos

$$\begin{aligned}(\psi_1 - \phi_1\psi_0)\mathbf{B} &= 0\mathbf{B} \Rightarrow \\ \psi_1 - \phi_1\psi_0 &= 0 \text{ y, ya que } \psi_0 = 1 \Rightarrow \\ \psi_1 &= \phi_1\end{aligned}$$

para los coeficientes de $\mathbf{B}^2$, tenemos

$$(\psi_2 - \phi_1\psi_1 - \phi_2\psi_0)\mathbf{B}^2 = 0\mathbf{B}^2 \Rightarrow \psi_2 - \phi_1\psi_1 - \phi_2\psi_0 = 0 \Rightarrow \psi_2 = \phi_1\psi_1 + \phi_2\psi_0 = \phi_1^2 + \phi_2$$

En general, para los coeficientes asociados a $\mathbf{B}^k$, tenemos

$$(\psi_k - \phi_1\psi_{k-1} - \phi_2\psi_{k-2} - \cdots - \phi_p\psi_{k-p})\mathbf{B}^k = 0\mathbf{B}^k$$

de donde obtenemos el siguiente resultado. Para un proceso estacionario AR(p), $\phi(\mathbf{B})X_t = Z_t$, su representación de la forma $X_t = \psi(\mathbf{B})Z_t$, está dada por la forma recursiva de los coeficientes ψ_k

$$\psi_k = \phi_1\psi_{k-1} + \phi_2\psi_{k-2} + \cdots + \phi_p\psi_{k-p}$$

con los valores iniciales

$$\psi_0 = 1, \quad \psi_k = 0 \quad \forall k < 0$$

En nuestro ejemplo

$$X_t = 1.3X_{t-1} - 0.4X_{t-2} + Z_t$$

$$\phi_1 = 1.3, \quad \phi_2 = -0.4 \Rightarrow \psi_k = 1.3\psi_{k-1} - 0.4\psi_{k-2}, \quad \text{con } \psi_0 = 1, \psi_{-1} = 0$$

Los primeros valores calculados con esta fórmula recursiva son

1.30000000 1.29000000 1.15700000 0.98810000 0.82173000 0.67300900 0.54621970 0.44088201
0.35465873 0.28470355 0.22825112 0.18284504 0.14639810 0.11717952 0.09377413 0.07503456
0.06003528 0.04803204

mismos que se obtienen evaluando la expresión

$$\psi_k = \left(-\frac{5}{3}(0.5)^k + \frac{8}{3}(0.8)^k \right)$$

para $k=1,2,\dots$. Observemos que estos coeficientes decrecen a cero, condición necesaria pero no suficiente para que el proceso sea estacionario.

Funciones de autocovarianza y autocorrelación de un proceso AR(p)

Ahora calcularemos la función de autocorrelación de un AR(p) general. Primero, recordar que $\gamma(k)$, puede calcularse como

$$\gamma(k) = \rho(k)\gamma(0)$$

Entonces, del modelo AR(p), tenemos

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + Z_t$$

Si multiplicamos el modelo por X_t en ambos lados de la igualdad, tenemos

$$\gamma(0) = \mathbb{E}[X_t^2] = \phi_1 \underbrace{\mathbb{E}[X_t X_{t-1}]}_{\gamma(1)} + \phi_2 \underbrace{\mathbb{E}[X_t X_{t-2}]}_{\gamma(2)} + \cdots + \phi_p \underbrace{\mathbb{E}[X_t X_{t-p}]}_{\gamma(p)} + \underbrace{\mathbb{E}[X_t Z_t]}_{\sigma_Z^2}$$

sustituyendo el valor de $\gamma(k) = \rho(k)\gamma(0)$, y despejando $\gamma(0)$, se tiene

$$\gamma(0) = \frac{\sigma_Z^2}{1 - \phi_1 \rho(1) - \phi_2 \rho(2) - \cdots - \phi_p \rho(p)}$$

Para calcular la función de autocorrelación, multipliquemos el modelo por X_{t-k} , y tomemos la esperanza de esa expresión

$$\underbrace{\mathbb{E}[X_t X_{t-k}]}_{\gamma(k)} = \phi_1 \underbrace{\mathbb{E}[X_{t-1} X_{t-k}]}_{\gamma(k-1)} + \phi_2 \underbrace{\mathbb{E}[X_{t-2} X_{t-k}]}_{\gamma(k-2)} + \cdots + \phi_p \underbrace{\mathbb{E}[X_{t-p} X_{t-k}]}_{\gamma(k-p)} + \underbrace{\mathbb{E}[Z_t X_{t-k}]}_{=0}$$

si dividimos por $\gamma(0)$, obtenemos la forma recursiva para calcular $\rho(k)$

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2) + \cdots + \phi_p \rho(k-p)$$

con $\rho(0) = 1$ y $\rho(-k) = \rho(k)$.

Entonces, las ecuaciones de Yule-Walker, son




$$\begin{cases} \rho(1) = \phi_1 + \phi_2\rho(1) + \cdots + \phi_p\rho(p-1) & \text{recordar que } \rho(p) = \rho(-p) \\ \rho(2) = \phi_1\rho(1) + \phi_2 + \cdots + \phi_p\rho(p-2) \\ \vdots \\ \rho(p) = \phi_1\rho(p-1) + \phi_2\rho(p-2) + \cdots + \phi_p \end{cases}$$

Y para $p = 1, 2, \dots$ este sistema se puede escribir como

$$\begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} 1 & \rho(1) & \rho(2) & \cdots & \rho(p-1) \\ \rho(1) & 1 & \rho(1) & \cdots & \rho(p-2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho(p-1) & \rho(p-2) & \rho(p-3) & \cdots & 1 \end{pmatrix}^{-1} \begin{pmatrix} \rho(1) \\ \rho(2) \\ \vdots \\ \rho(p) \end{pmatrix}$$

Cuya solución para encontrar los valores ϕ_k , $k = 1, 2, \dots$ es

$$\phi_k = \frac{\begin{vmatrix} 1 & \rho(1) & \rho(2) & \cdots & \rho(p-2) & \rho(1) \\ \rho(1) & 1 & \rho(1) & \cdots & \rho(p-3) & \rho(2) \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho(p-1) & \rho(p-2) & \rho(p-3) & \cdots & \rho(1) & \rho(p) \end{vmatrix}}{\begin{vmatrix} 1 & \rho(1) & \rho(2) & \cdots & \rho(p-2) & \rho(p-1) \\ \rho(1) & 1 & \rho(1) & \cdots & \rho(p-3) & \rho(p-2) \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho(p-1) & \rho(p-2) & \rho(p-3) & \cdots & \rho(1) & 1 \end{vmatrix}}$$



Procesos ARMA(p,q)

Los modelos AR(p) son una clase general de procesos estocásticos que son prácticamente suficientes para las aplicaciones reales. No obstante, una forma de ampliar esta clase de modelos para series de tiempo, es incluir un proceso de medias móviles MA(q), para generar el proceso mixto conocido como *proceso auto regresivo de medias móviles ARMA(p,q)*.

Entonces, se dice que X_t es un proceso autoregresivo de medias móviles (denotado como ARMA(p,q)) si


$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \cdots + \theta_q Z_{t-q}$$

equivalentemente

$$X_t = \sum_{i=1}^p \phi_i X_{t-i} + Z_t + \sum_{i=1}^q \theta_i Z_{t-i}$$

o

$$\phi(\mathbf{B})X_t = \theta(\mathbf{B})Z_t$$



Representación como un proceso de medias móviles

Antes de hacer la representación general, la ilustraremos con el modelo ARMA(1,1). Entonces, el proceso ARMA(1,1) es

$$X_t = \phi X_{t-1} + Z_t + \theta Z_{t-1}$$

que podemos escribir como

$$\begin{aligned} X_t &= (1 - \phi \mathbf{B})^{-1} (1 + \theta \mathbf{B}) Z_t = (1 + \phi \mathbf{B} + \phi^2 \mathbf{B}^2 + \dots) (1 + \theta \mathbf{B}) Z_t \\ &= \left(\sum_{i=0}^{\infty} \phi^i \mathbf{B}^i \right) (1 + \theta \mathbf{B}) Z_t \\ &= \left(1 + \sum_{i=1}^{\infty} \phi^i \mathbf{B}^i + \sum_{i=0}^{\infty} \theta \phi^i \mathbf{B}^{i+1} \right) Z_t \end{aligned}$$

Ahora, desarrollemos las funciones de autocovarianza y de autocorrelación para este proceso

particular. Del proceso original

$$X_t = \phi X_{t-1} + Z_t + \theta Z_{t-1}$$

multiplicando en ambos lados de la igualdad por X_t y tomando esperanzas

$$\gamma_0 = \phi \mathbb{E}[X_t X_{t-1}] + \mathbb{E}[X_t Z_t] + \theta \mathbb{E}[X_t Z_{t-1}]$$

Por otro lado, multiplicando la misma igualdad pero ahora por Z_t , y tomando esperanzas, tenemos

$$\mathbb{E}[X_t Z_t] = \phi \mathbb{E}[X_{t-1} Z_t] + \mathbb{E}[Z_t^2] + \theta \mathbb{E}[Z_{t-1} Z_t] = \sigma_Z^2$$

ya que Z_{t-1} depende las Z' s hasta el tiempo $t-1$, pero no depende de Z_t . Además

$$\mathbb{E}[X_t Z_{t-1}] = \phi \mathbb{E}[X_{t-1} Z_{t-1}] + \mathbb{E}[Z_t Z_{t-1}] + \theta \mathbb{E}[Z_{t-1}^2] = \phi \sigma_Z^2 + \theta \sigma_Z^2$$

De estas igualdades tenemos que

$$\gamma(0) = \phi \gamma(1) + [1 + \theta(\phi + \theta)] \sigma_Z^2$$

Ahora, para la función de autocovarianza en general, siguiendo el mismo proceso pero multiplicando por X_{t-k} , tenemos que

$$\begin{aligned} \gamma(k) &= \phi \mathbb{E}[X_{t-k} X_{t-1}] + \mathbb{E}[X_{t-k} Z_t] + \theta \mathbb{E}[X_{t-k} Z_{t-1}] \\ &= \begin{cases} \phi \gamma(0) + \theta \sigma_Z^2, & \text{si } k = 1 \\ \phi \gamma(k-1), & \text{si } k \geq 2 \end{cases} \end{aligned}$$

Puede observarse que conocidas las dos primeras autocovarianzas, $\gamma(0)$ y $\gamma(1)$, el resto pueden encontrarse fácilmente. Para obtener estas dos primeras, es necesario resolver el sistema

$$\begin{aligned} \gamma(0) &= \phi \gamma(1) + [1 + \theta(\phi + \theta)] \sigma_Z^2 \\ \gamma(1) &= \phi \gamma(0) + \theta \sigma_Z^2 \end{aligned}$$

cuya solución es

$$\begin{aligned}\gamma(0) &= \frac{(1 + 2\phi\theta + \theta^2)\sigma_Z^2}{1 - \phi^2} \\ \gamma(1) &= \frac{(1 + \phi\theta)(\phi + \theta)\sigma_Z^2}{1 - \phi^2}\end{aligned}$$

por lo tanto

$$\gamma(k) = \frac{\phi^{k-1}(1 + \phi\theta)(\phi + \theta)\sigma_Z^2}{1 - \phi^2}, \quad k = 1, 2, \dots$$

y la correspondiente función de autocorrelación está dada por

$$\rho(k) = \frac{\phi^{k-1}(1 + \phi\theta)(\phi + \theta)}{1 + 2\phi\theta + \theta^2}, \quad k = 1, 2, \dots$$

Representación de un ARMA(p,q) como un proceso de medias móviles

Ahora hagamos la representación de un proceso general ARMA(p,q) como su correspondiente proceso de medias móviles. De la representación del ARMA(p,q) en términos de los operadores de retraso, se tiene

$$X_t = \frac{\theta(\mathbf{B})}{\phi(\mathbf{B})} Z_t = \psi(\mathbf{B})\theta(\mathbf{B})Z_t = \chi(\mathbf{B})Z_t \Rightarrow \theta(\mathbf{B})Z_t = \phi(\mathbf{B})\chi(\mathbf{B})Z_t$$

entonces, igualando los polinomios en $\mathbf{B}$

$$1 + \theta_1\mathbf{B} + \theta_2\mathbf{B}^2 + \dots + \theta_q\mathbf{B}^q = (1 - \phi_1\mathbf{B} - \phi_2\mathbf{B}^2 - \dots - \phi_p\mathbf{B}^p)(\chi_0 + \chi_1\mathbf{B} + \chi_2\mathbf{B}^2 + \dots)$$

de donde se desprende que

$$\begin{aligned}\chi_0 &= 1 \\ \chi_1 - \chi_0\phi_1 &= \theta_1 \\ \chi_2 - \chi_1\phi_1 - \chi_0\phi_2 &= \theta_2 \\ &\vdots\end{aligned}$$

y, de forma general

$$\chi_j - \sum_{k=1}^p \phi_k \chi_{j-k} = \theta_j, \quad j = 0, 1, 2, \dots$$

con $\theta_0 = 1$, $\theta_j = 0$ para $j > q$ y $\chi_j = 0$ si $j < 0$.

Funciones de autocovarianza y autocorrelación de un ARMA(p,q)

Ya que es posible escribir el proceso AR(p,q) como uno de medias móviles infinito, entonces $E(X_t) = 0$. Ahora, para deducir las funciones de autocovarianza y autocorrelación, consideremos la expresión del proceso

$$X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} - \dots - \phi_p X_{t-p} = Z_t + \theta_1 Z_{t-1} + \dots + \theta_q Z_{t-q}$$

multiplicando en ambos lados de la igualdad por X_{t-k} , $k = 0, 1, 2, \dots$, tomando esperanzas, y recordado que este proceso se puede escribir como un modelo de Medias Móviles infinito $\mathbf{MA}(\infty)$

$$\begin{aligned} X_t &= \sum_{j=0}^{\infty} \psi_j Z_{t-j} \\ X_{t-k} &= \sum_{j=0}^{\infty} \psi_j Z_{t-k-j} \end{aligned}$$

tenemos que

$$\begin{aligned} \mathbb{E}(X_t X_{t-k} - \phi_1 X_{t-1} X_{t-k} - \phi_2 X_{t-2} X_{t-k} - \dots - \phi_p X_{t-p} X_{t-k}) &= \mathbb{E}(\theta_k Z_{t-k} X_{t-k} + \dots + \theta_q Z_{t-q} X_{t-k}) \\ \gamma(k) - \phi_1 \gamma(k-1) - \phi_2 \gamma(k-2) - \dots - \phi_p \gamma(k-p) &= \mathbb{E}(\theta_k Z_{t-k} X_{t-k} + \dots + \theta_q Z_{t-q} X_{t-k}) \end{aligned}$$

de donde obtenemos

$$\gamma(k) - \phi_1 \gamma(k-1) - \phi_2 \gamma(k-2) - \dots - \phi_p \gamma(k-p) = \sigma_Z^2 \sum_{j=0}^q \theta_j \psi_{j-k}, \quad 0 \leq k < \max(p, q)$$

Y la función de autocorrelación es

$$\rho(k) = \begin{cases} \phi_1\rho(k-1) - \phi_2\rho(k-2) - \dots - \phi_p\rho(k-p) + \frac{\sum_{j=0}^q \theta_j \psi_{j-k}}{\sum_{j=0}^{\infty} \psi_j^2}, & 0 \leq k \leq q \\ \phi_1\rho(k-1) - \phi_2\rho(k-2) - \dots - \phi_p\rho(k-p), & \text{si } k > q \end{cases}$$

Modelos ARIMA(p,d,q)

En la introducción del modelo de caminata aleatoria, vimos que no era estacionario, porque tanto su media como su varianza eran funciones de t , sin embargo, el proceso definido por las diferencias $\nabla X_t = X_t - X_{t-1}$, sí es estacionario. Muchas series presentan dos componentes: un componente de tendencia *no estacionario* y otro componente de media cero estacionario. Por ejemplo

$$X_t = \mu_t + Z_t$$

con $\mu_t = \beta_0 + \beta_1 t$ y Z_t un proceso estacionario. Pero, diferenciando este proceso obtenemos uno estacionario

$$\nabla X_t = X_t - X_{t-1} = \beta_0 + \beta_1 t + Z_t - (\beta_0 + \beta_1(t-1) + Z_{t-1}) = \beta_1 + Z_t - Z_{t-1}$$

Si el componente de tendencia no estacionaria μ_t fuera un polinomio de grado k , por ejemplo, i.e. $\mu_t = \sum_{j=0}^k \beta_j t^j$, entonces necesitaríamos diferenciar k veces la serie ($\nabla^k X_t$) para que fuera estacionaria. El *modelo ARMA integrado* mejor conocido como *ARIMA* permite ampliar la clase de modelos ARMA para incluir diferenciación.

Modelo ARIMA(p,d,q)

Se dice que el proceso X_t es *ARIMA(p,d,q)*, si


$$\nabla^d X_t = (1 - \mathbf{B})^d X_t$$

es un modelo *ARMA(p,q)*. Escribiremos de forma general estos modelos como

$$\phi(\mathbf{B})(1 - \mathbf{B})^d X_t = \theta(\mathbf{B})Z_t$$

Por supuesto, si $d = 0$, entonces el proceso es estacionario, de hecho, es un *ARMA(p,q)*. Los modelos *ARIMA* son apropiados para modelar datos con tendencia. Estos modelos pueden extenderse para incluir términos estacionales (ciclos), proporcionando un *ARIMA* no estacionario estacional, conocido como *SARIMA*. Un modelo *ARIMA* estacional, utiliza diferencias

iguales al periodo de retraso (ciclo) que se quiere remover. Una serie puede ser no estacionaria también por cambios en la varianza, conocida como *heteroscedasticidad*, que usualmente da como resultado periodos de *volatilidad*, en los que hay un claro cambio en la varianza de la serie. Este comportamiento es común en series financieras, pero puede ocurrir también en otras como las series climáticas.



Transformaciones Box-Cox

Algunas veces la no estacionariedad de la series se debe a que ésta es intrínsecamente no lineal. En estos casos, es necesario necesario transformar la serie para lograr que la variabilidad se estabilice. Una transformación particularmente útil para estos fines es la de *Box-Cox*, definida como

$$Y_t = \begin{cases} \frac{(X_t^\lambda - 1)}{\lambda}, & \lambda \neq 0 \\ \log(X_t), & \text{si } \lambda = 0 \end{cases}$$

Existen diversos métodos para estimar el valor de λ en un caso particular. Algunas veces, esta transformación no sólo estabiliza la varianza, sino también hace que la serie sea lineal y se distribuya normal.

La siguiente tabla muestra el rango de valores de λ que estarían asociados a una transformación analítica común.

Relación λ y transformaciones analíticas		
Rango λ	Transformación analítica asociada	Nombre
$(-2.5, -1.5]$	$\frac{1}{y^2}$	Inversa cuadrada
$(-1.5, -0.75]$	$\frac{1}{y}$	Recíproca
$(-0.75, -0.25]$	$\frac{1}{\sqrt{y}}$	Inversa raíz cuadrada
$(-0.25, 0.25]$	$\ln(y)$	Logaritmo natural
$(0.25, 0.75]$	$\sqrt{y}$	Raíz cuadrada
$(0.75, 1.25]$	y	Idéntica o ninguna
$(1.5, 2.5)$	y^2	Cuadrada

Identificabilidad

Supongamos que tenemos una familia de modelos (distribuciones) $\{P_\theta; \theta \in \Theta\}$ para nuestros datos $\mathbf{X}$. Entonces, El modelo es *identificable* si $\theta_1 \neq \theta_2$ implica $P_{\theta_1} \neq P_{\theta_2}$, i.e., diferentes valores de θ dan diferentes modelos para los datos. Por otro lado, un modelo es *no identificable* si hay diferentes valores de θ que proporcionan exactamente las mismas predicciones sobre los datos, i.e., los datos no distinguen entre estos valores de θ .

Estacionariedad e invertibilidad

Hemos visto que todos los procesos analizados hasta ahora, son estacionarios de segundo orden, e intentamos caracterizarlos a través de sus primeros momentos: media, función de autocovarianza y de autocorrelación. Sin embargo, aunque un proceso tiene una única estructura de covarianza, el reverso no es cierto en general. Por ejemplo, los procesos de medias móviles

$$\begin{aligned} X_t &= Z_t + \theta Z_{t-1} \text{ y} \\ X_t &= Z_t + \frac{1}{\theta} Z_{t-1} \end{aligned}$$

tienen exactamente la misma función de autocorrelación, es decir, esta función *no identifica de manera única* a este proceso MA. Si “invertimos” ambos modelos, en el sentido de cambiar los roles de X_t y Z_t , entonces

$$\begin{aligned} Z_t &= X_t - \theta X_{t-1} + \theta^2 X_{t-2} - \dots \\ Z_t &= X_t - \frac{1}{\theta} X_{t-1} + \frac{1}{\theta^2} X_{t-2} - \dots \end{aligned}$$

Si $|\theta| < 1$, la serie de coeficientes de X_{t-j} converge para el modelo superior, pero no para el modelo inferior. Entonces, este último modelo es *no invertible*. De manera general, un proceso X_t , se dice que es *invertible*, si su término aleatorio Z_t , puede escribirse como

$$Z_t = \sum_{j=0}^{\infty} \psi_j X_{t-j}$$

con $\sum_{j=0}^{\infty} \psi_j < \infty$. La imposición de invertibilidad garantiza que hay un único proceso MA para cada función de autocorrelación. Esta condición de invertibilidad para un proceso MA, es más fácil de enunciar utilizando el operador de retraso $\mathbf{B}$. Recordemos que escribimos el proceso MA(q) como

$$\begin{aligned} X_t &= (\beta_0 + \beta_1 \mathbf{B} + \beta_2 \mathbf{B}^2 + \cdots + \beta_q \mathbf{B}^q) Z_t \\ &= \theta(\mathbf{B}) Z_t \end{aligned}$$

Donde $\theta(\mathbf{B})$ es un polinomio de orden q en $\mathbf{B}$. Se puede demostrar que un proceso MA(q) es invertible si las raíces de la ecuación

$$\theta(\mathbf{B}) = \beta_0 + \beta_1 \mathbf{B} + \beta_2 \mathbf{B}^2 + \cdots + \beta_q \mathbf{B}^q = 0$$

se encuentran *fuera del círculo unitario* (en el plano complejo). Aquí $\mathbf{B}$ se asume como una variable compleja y no como un operador. Esto significa que las raíces, que pueden ser complejas, tienen *modulo mayor que uno*.

Ya que podemos factorizar el polinomio como

$$\theta(\mathbf{B}) = (1 - g_1 \mathbf{B})(1 - g_2 \mathbf{B}) \cdots (1 - g_q \mathbf{B}) = 0$$

entonces, el proceso MA(q) será invertible si

$$|g_i| < 1, \quad \text{para } i = 1, 2, \dots, q$$

ya que las raíces de este polinomio $r_i = g_i^{-1}$ se encuentran fuera del círculo unitario, i.e., $|r_i| > 1$. Por ejemplo, en un MA(1), tenemos

$$\theta(\mathbf{B}) = 1 + \theta \mathbf{B}$$

cuya raíz es $r = -1/\theta$, que es real, y estará fuera del círculo unitario si $|\theta| < 1$. Esta condición de invertibilidad es equivalente a la condición de estacionariedad del proceso.

Consideremos un proceso AR(p). Entonces satisface

$$\begin{aligned}(1 - \alpha_1 \mathbf{B} - \alpha_2 \mathbf{B}^2 - \dots - \alpha_p \mathbf{B}^p) X_t &= Z_t \\ &= \phi(\mathbf{B}) X_t = Z_t\end{aligned}$$

con $\phi(\mathbf{B})$ un polinomio de grado p , que tiene p raíces. Lo que significa que se puede factorizar como

$$\phi(\mathbf{B}) = \prod_{j=1}^p (1 - b_j \mathbf{B})$$

con raíces $1/b_j$, $j=1,2,\dots,p$.

Si regresamos a la definición del proceso AR(p), tenemos

$$\prod_{j=1}^p (1 - b_j \mathbf{B}) X_t = Z_t$$

entonces

$$X_t = \prod_{j=1}^p (1 - b_j \mathbf{B})^{-1} Z_t$$

pero $(1 - b_j \mathbf{B})^{-1}$ existe si

$$\sum_{k=0}^{\infty} b_j^k \mathbf{B}^k < \infty$$

que ocurre si $|b_j| < 1$. Entonces, un AR(p) es estacionario si todas las raíces del polinomio característico ϕ son mayores que 1 en valor absoluto. Estas raíces pueden ser complejas.

El resultado anterior proporciona una manera simple de investigar si un AR(p) es estacionario y además invertible.

Ejemplo

En el AR(2) que ya habíamos considerado anteriormente

$$X_t = 1.3X_{t-1} - 0.4X_{t-2} = Z_t$$

tenemos que $\phi(\mathbf{B}) = 1 - 1.3\mathbf{B} + 0.4\mathbf{B}^2 = (1 - 0.5\mathbf{B})(1 - 0.8\mathbf{B})$, cuyas raíces son $r_1 = 2$ y $r_2 = 1.25$ que tienen módulo mayor a 1. Por lo tanto el modelo es estacionario e invertible. Además, vimos que se podía escribir como un proceso de medias móviles

$$X_t = \sum_{i=0}^{\infty} \left(-\frac{5}{3}(0.5)^i + \frac{8}{3}(0.8)^i \right) Z_{t-i}$$

entonces, concluimos que para la representación en términos de $\psi(\mathbf{B})$

$$\psi_k = \left(-\frac{5}{3}(0.5)^k + \frac{8}{3}(0.8)^k \right)$$

y observamos que $\psi_k \downarrow 0$, y esta serie converge.

Teorema de Schur

Los módulos de las raíces de la ecuación

$$\mathbf{B}^p - \alpha_1\mathbf{B}^{p-1} - \dots - \alpha_{p-1}\mathbf{B} - \alpha_p = 0$$

serán todos *menores que uno*, si y sólo si, los p determinantes que se muestran a continuación son positivos

$$D_1 = \begin{vmatrix} -1 & \alpha_p \\ \alpha_p & -1 \end{vmatrix}, \quad D_2 = \begin{vmatrix} -1 & 0 & \alpha_p & \alpha_{p-1} \\ \alpha_{p-1} & -1 & 0 & \alpha_p \\ \alpha_p & 0 & -1 & \alpha_{p-1} \\ \alpha_{p-1} & \alpha_p & 0 & -1 \end{vmatrix}, \dots$$

$$D_p = \begin{vmatrix} -1 & 0 & \dots & 0 & \alpha_p & \alpha_{p-1} & \dots & \alpha_1 \\ \alpha_1 & -1 & \dots & 0 & 0 & \alpha_p & \dots & \alpha_2 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ \alpha_{p-1} & \alpha_{p-2} & \dots & -1 & 0 & 0 & \dots & \alpha_p \\ \alpha_p & 0 & \dots & 0 & -1 & \alpha_1 & \dots & \alpha_{p-1} \\ \alpha_{p-1} & \alpha_p & \dots & 0 & 0 & -1 & \dots & \alpha_{p-2} \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ \alpha_1 & \alpha_2 & \dots & \alpha_p & 0 & 0 & \dots & -1 \end{vmatrix}$$

Por ejemplo, si el polinomio característico es: $1 - \alpha_1 \mathbf{B} - \alpha_2 \mathbf{B}^2$, entonces

$$D_1 = \begin{vmatrix} -1 & \alpha_2 \\ \alpha_2 & -1 \end{vmatrix} = 1 - \alpha_2^2 \quad y$$

$$D_2 = \begin{vmatrix} -1 & 0 & \alpha_2 & \alpha_1 \\ \alpha_1 & -1 & 0 & \alpha_2 \\ \alpha_2 & 0 & -1 & \alpha_1 \\ \alpha_1 & \alpha_2 & 0 & -1 \end{vmatrix} = (1 + \alpha_2)^2 [(1 - \alpha_2)^2 - \alpha_1^2]$$

De donde la condición $D_1 > 0 \Rightarrow |\alpha_2| < 1$, mientras que $D_2 > 0 \Rightarrow (1 - \alpha_2)^2 > \alpha_1^2$, entonces

$$|\alpha_2| < 1, \quad \alpha_2 + \alpha_1 < 1, \quad \alpha_2 - \alpha_1 < 1$$

lo que hace aún más fácil verificar las condiciones de invertibilidad, en términos de los coeficientes del polinomio característico del proceso.

Consideremos un MA(2) dado por

$$X_t = 0.3Z_{t-1} - 0.2Z_{t-2} + Z_t = (1 - \alpha_1 \mathbf{B} - \alpha_2 \mathbf{B}^2)Z_t$$

Entonces: $\alpha_2 = 0.2$, $\alpha_1 = -0.3$. Y $|\alpha_2| = 0.2$, $\alpha_2 + \alpha_1 = 0.2 - 0.3 = -0.1 < 1$ y $\alpha_2 - \alpha_1 = 0.2 - (-0.3) = 0.5 < 1$. Por lo tanto, este MA(2) es invertible.

Finalmente, todo proceso MA(q) es estacionario, ya que es una suma ponderada finita de “choques aleatorios.” de términos de “ruido blanco”, pero es invertible si las raíces del polinomio característico están fuera del círculo unitario. Y como vimos, las condiciones de estacionariedad de un AR(p) implican que las raíces de su polinomio característico deben estar fuera del círculo unitario, por lo tanto, cualquier proceso AR(p) estacionario, es invertible.

Invertibilidad y estacionariedad para el proceso ARMA(p,q)

Recordemos que este proceso se puede escribir en términos de los operadores de retraso

$$\phi(\mathbf{B})X_t = \theta(\mathbf{B})Z_t$$

entonces, como consecuencia de los resultados anteriores, si todas las raíces del polinomio característico asociado a $\phi(\mathbf{B})$ tienen módulo menor que uno, entonces el modelo es estacionario, y si las raíces del polinomio característico asociado a $\theta(\mathbf{B})$ están fuera del círculo

unitario, entonces el proceso es invertible.

Especificación del modelo para una serie de tiempo

Hasta aquí hemos desarrollado una clase amplia de modelos paramétricos para ajustar tanto una serie estacionaria como una no estacionaria: *Los modelos ARIMA*. Ahora, debemos estudiar cómo implementar estos modelos, además de la manera de realizar inferencias con ellos. Nuestros objetivos serán

- Elegir de manera apropiada los valores (p, d, q) para los datos de una serie real
- Estimar los parámetros del modelo ARIMA(p,d,q) especificado en el punto anterior
- Verificar lo apropiado del ajuste del modelo así como sus supuestos

La estrategia general para lograr estos objetivos, iniciará con la elección razonable, aunque tentativa, de los valores de (p, d, q) . Una vez realizada la tarea anterior, deberemos estimar, de la forma más eficiente posible, los parámetros: $\underline{\phi}$, $\underline{\theta}$ y σ_Z^2 , involucrados en el modelo. Finalmente, debemos juzgar de manera crítica el ajuste del modelo que obtuvimos para verificar lo adecuado del mismo. Si el modelo no parece adecuado, debemos considerar en qué sentido no es adecuado para que nos ayude a proponer otro modelo. Procederemos de forma semejante con el nuevo modelo, hasta obtener, si es posible, uno que ajuste adecuadamente a nuestros datos y que cumpla con los supuestos sobre los que se construyó.

Identificación

Aquí supondremos que la serie ya es estacionaria, bien sea porque de origen lo era o porque se transformó o diferenció para quitar tendencia o estacionalidad (ciclos). Estos procesos se hacen a partir de un primer análisis de la gráfica de la serie.

Empleo de la función de autocorrelación

Dada nuestra serie estacionaria, el siguiente paso consiste en asociar la función de autocovarianza (FAC) muestral con un posible modelo ARIMA. Para determinar cuántas autocorrelaciones pueden considerarse *estadísticamente significativas* a un nivel de significancia α . Barlett (1946) desarrolló aproximaciones para las varianzas y covarianzas de las autocorrelaciones muestrales, en caso de que el proceso sea generado a partir de ruido blanco con distribución normal

$$\begin{aligned}\mathbb{V}ar(r_k) &\approx \frac{1}{n} \sum_{j=-\infty}^{\infty} (\rho_j^2 + \rho_{j+k}\rho_{j-k} - 4\rho_k\rho_j\rho_{j-k} + 2\rho_j^2\rho_k^2) \\ \mathbb{C}ov(r_k, r_{k+s}) &\approx \frac{1}{n} \sum_{j=-\infty}^{\infty} \rho_j\rho_{j+s}\end{aligned}$$

Si el proceso es MA(q), que implica que las correlaciones para retrasos de la serie mayores a q deben ser cero, la expresión de la varianza se convierte en

$$\mathbb{V}ar(r_k) \approx \frac{1}{n-d} \left(1 + 2 \sum_{j=1}^q \rho_j^2 \right)$$

ya que ($j = k$) y d el número de diferencias aplicadas para lograr una serie estacionaria. Por lo tanto, bajo la hipótesis de que $\rho_k = 0$, para $k > q$, i.e., de que el modelo sea un MA(q), se obtiene esta última expresión. En la práctica, hay que sustituir los valores desconocidos de ρ_k por sus correspondientes valores estimados r_k , que proporciona una buena estimación para muestras grandes ($n > 50$).

Para probar si alguna de las correlaciones son iguales a cero a partir de un cierto retraso q , es necesario hacer la prueba de hipótesis correspondiente.

$$H_0 : \rho_k = 0 \quad vs. \quad H_a : \rho_k \neq 0$$

La prueba se realiza observando que si n es grande, entonces

$$r_k \stackrel{a}{\sim} N \left(0, \frac{1}{n} \sum_{j=-\infty}^{\infty} (\rho_j^2 + \rho_{j+k}\rho_{j-k} - 4\rho_k\rho_j\rho_{j-k} + 2\rho_j^2\rho_k^2) \right)$$

Una manera general de hacer este proceso es declarar que una autocorrelación poblacional es estadísticamente significativa a nivel α , si

$$|r_k| > Z_{1-\alpha/2} \sqrt{\frac{1}{n-d} \left(1 + 2 \sum_{j=1}^q r_j^2 \right)} \quad para \quad k > q$$

Generalmente, cuando se grafica el correlograma, los paquetes grafican las bandas de confianza (intervalo de confianza para ρ_k), con lo que se puede juzgar esta hipótesis. Si la correlación es estadísticamente significativa al nivel de confianza seleccionado, entonces la barra que la representa en el correlograma, rebasará cualquiera de las líneas que delimitan el intervalo.

Uso de la función de autocorrelación parcial (FACP)

La identificación de un MA(q) puede realizarse fácilmente mediante el uso de la FAC muestral; sin embargo, cuando se trata de identificar un AR(p), hacerlo mediante la FAC muestral no resulta tan simple. En general, el orden de un AR(p) *no es posible detectarlo* únicamente con el uso de la FAC muestral. En este caso, requerimos de la *función de autocorrelación parcial* para hacer la identificación de un modelo AR(p).

Para introducir el concepto de autocorrelación parcial, consideremos el modelo AR(1):

$X_t = \phi X_{t-1} + Z_t$. Para este proceso sabemos que $\rho_k = \phi^k$, $k = 0, 1, \dots$, y supongamos que queremos calcular la dependencia entre X_t y X_{t-2} sin tomar en cuenta a X_{t-1} , es decir, queremos calcular la correlación parcial

$$\rho_{02.1} = \frac{\rho_{02} - \rho_{01}\rho_{12}}{\sqrt{(1 - \rho_{01}^2)(1 - \rho_{12}^2)}}$$

donde $\rho_{02} = \rho_2 = \phi^2$ y $\rho_{01} = \rho_{12} = \phi$, ya que ρ_{02} denota la correlación entre X_t y X_{t-2} , mientras que ρ_{01} y ρ_{12} denotan las respectivas entre X_t y X_{t-1} y X_{t-1} y X_{t-2} . De estos resultados se tiene que $\rho_{02.1} = 0$. De hecho, puede demostrarse que todas las correlaciones parciales que excluyen a X_{t-1} son cero, como era de esperarse, ya que la única variable “independiente” del modelo en cuestión es X_{t-1} .

Consideremos ahora el modelo AR(2): $X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + Z_t$, que tiene a X_{t-1}, X_{t-2} como variables “independientes”. Se sabe que

$$\rho_1 = \frac{\phi_1}{(1 - \phi_2)} \quad y \quad \rho_2 = \phi_2 + \frac{\phi_1^2}{(1 - \phi_2)}$$

de aquí obtenemos

$$\rho_{02.1} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2} = \phi_2$$

es decir, la contribución de X_{t-2} para explicar a X_t se mide sólo a través de ϕ_2 . Si recordamos la teoría del modelo de regresión, debe ser evidente que los coeficientes del modelo autorregresivo deben ser iguales a las correlaciones parciales. Entonces, para decidir *el orden del proceso AR subyacente*, debemos verificar si una correlación parcial, equivalentemente, si un coeficiente del modelo AR es estadísticamente significativo, Quenouille (1949), desarrolló una aproximación para la media y varianza de las autocorrelaciones parciales muestrales

$$E(\hat{\phi}_i) = \phi_i \quad y \quad Var(\hat{\phi}_i) \approx \frac{1}{n - d} \quad para \quad i > p$$

Se puede realizar la prueba de hipótesis correspondiente, o utilizar el correspondiente intervalo de confianza al nivel α asociado. Se declara que la autocorrelación parcial poblacional ϕ_k es estadísticamente distinta de cero, si el valor de $\hat{\phi}_i$ se encuentra fuera del intervalo

$$\pm Z_{1-\alpha/2} \sqrt{Var(\hat{\phi}_i)} \approx \frac{Z_{1-\alpha/2}}{\sqrt{n - d}}$$


Finalmente, es importante decir que mientras un proceso $AR(p)$ tiene sólo las primeras p autocorrelaciones parciales distintas de cero, un proceso $MA(q)$ (que es equivalente a un proceso $AR(\infty)$), tendrá todas las autocorrelaciones parciales distintas de cero, aunque la FACP muestre convergencia a cero. De manera similar, un proceso $ARMA(p,q)$ tendrá asociada una FACP que no desaparece después de un número finito de retrasos.

Comportamiento típico de las funciones FAC y FACP


Las características usuales de las funciones FAC y FACP de una serie estacionaria, se resumen en el siguiente cuadro.

Proceso	FAC	FACP
AR(p)	Convergencia a cero, con comportamiento dictado por la ecuación $\phi(\mathbf{B})\rho_k = 0$, para $k \geq p$	Solamente las primeras p autocorrelaciones parciales son distintas de cero
MA(q)	Sólo las primeras q autocorrelaciones son distintas de cero	Sucesión infinita convergente a cero
ARMA(p,q)	Comportamiento irregular de las primeras q autocorrelaciones y después convergencia a cero de acuerdo con $\phi(\mathbf{B})\rho_k = 0$, para $k > q$	Sucesión infinita convergente a cero


Comportamiento típico de la ACF en un MA




Comportamiento típico de la PACF en un MA




Comportamiento típico ACF en un AR




Comportamiento típico PACF en un AR



Comportamiento típico ACF en un ARMA



Comportamiento típico PACF en un ARMA



Estimación

En esta etapa se asume que ya se ha identificado un modelo razonable para nuestros datos, y que lo que resta es encontrar los valores de los parámetros que lo determinan. Es decir, una vez que hemos propuesto los órdenes de los modelos autorregresivo y de promedios móviles, p, q , además del grado de diferenciación requerido, d , postulamos el modelo

$$\phi(\mathbf{B})\nabla^d T(X_t) = \theta(\mathbf{B})Z_t$$

entonces, debemos estimar los valores de $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$, a partir de los datos de la serie de tiempo bajo estudio.

Máxima verosimilitud

Generalmente, para implementar un proceso de estimación por máxima verosimilitud, necesitamos asignar una distribución a nuestros datos. En el caso de series de tiempo, supondremos que el proceso de ruido blanco, $\{Z_t\}$ sigue una distribución normal de media cero y varianza σ_Z^2 . Cuya función de densidad conjunta está dada por

$$f(Z_1, \dots, Z_n) = (2\pi)^{-n/2} \sigma_Z^{-n} \exp \left\{ -\frac{\sum_{t=1}^n Z_t^2}{2\sigma_Z^2} \right\}$$

Entonces, si definimos la variable $W_t = \nabla^d T(X_t)$, tenemos que, para el proceso **ARMA** $(\mathbf{p}, \mathbf{q})$ de la serie, tal vez, diferenciada y transformada, se tiene

$$Z_t = W_t - \phi_1 W_{t-1} - \dots - \phi_p W_{t-p} + \theta_1 Z_{t-1} + \dots + \theta_q Z_{t-q}$$

y la densidad conjunta o verosimilitud de las W_i 's, es

$$L(\underline{\phi}, \underline{\theta}, \sigma_Z^2 | \underline{W}) =$$

$$(2\pi)^{-n/2} \sigma_Z^{-n} \exp \left\{ -\sum_{t=1}^n (W_t - \phi_1 W_{t-1} - \dots - \phi_p W_{t-p} + \theta_1 Z_{t-1} + \dots + \theta_q Z_{t-q})^2 / 2\sigma_Z^2 \right\}$$

El siguiente paso, una vez planteada la verosimilitud, es maximizarla con respecto a cada uno de los parámetros involucrados. El proceso de estimación produce, generalmente, ecuaciones no lineales, que tienen que resolverse por métodos numéricos. Primero se encuentran

los estimadores $\hat{\underline{\phi}}, \hat{\underline{\theta}}$, y posteriormente $\hat{\sigma}_Z^2$. Para realizar inferencias (pruebas de hipótesis e intervalos de confianza) sobre estos parámetros, es necesario calcular sus varianzas asintóticas a través de la llamada *matriz de información observada de Fisher*, que definimos en la sección de supervivencia.

Verificación

La etapa de verificación parte de la idea de que *todos los modelos son erróneos*, puesto que son sólo representaciones simplificadas de la realidad. Entonces, si hay que elegir entre varios modelos, habrá que elegir aquél que presente menos fallas, o bien, fallas menos importantes. Por tal motivo, habrá que poner en tela de juicio a los posibles modelos para detectar sus fallas, que se evidencian como violaciones a los supuestos sobre los que se construyeron.

Análisis de residuos

Una de las formas más simples para detectar violaciones a los supuestos de los modelos, es a través del *análisis de residuos*, en donde, como *residuo* se entiende aquella parte de las observaciones que no es explicada por el modelo. Los residuos para el modelo ARMA(p,q), $\phi(\mathbf{B})W_t = \theta(\mathbf{B})Z_t$, se definen como

$$\begin{aligned}\hat{Z}_t &= \hat{\theta}(\mathbf{B})^{-1} \hat{\phi}(\mathbf{B})W_t \\ &= \hat{\psi}W_t\end{aligned}$$

de esta igualdad se tiene que

$$W_t = \hat{Z}_t + \hat{\psi}_1 W_{t-1} + \hat{\psi}_2 W_{t-2} + \cdots$$

La estimación de W_t se puede hacer mediante el polinomio estimado $\hat{\psi}(\mathbf{B})$ y las observaciones al tiempo $t-1$, y es

$$\hat{W}_t = \hat{\psi}_1 W_{t-1} + \hat{\psi}_2 W_{t-2} + \cdots$$

de estas dos últimas expresiones se obtiene

$$\hat{Z}_t = W_t - \hat{W}_t$$

y concluimos que los residuos miden la discrepancia entre los valores observados de la series y sus valores estimados, como es usual. Al analizar los residuos observados $\{\hat{Z}_t\}$, se analiza, básicamente, una realización del proceso, *no observado*, de ruido blanco $\{Z_t\}$. Por lo que los supuestos del proceso $\{Z_t\}$ pueden verificarse a través de los residuos observados $\{\hat{Z}_t\}$.

- El proceso de ruido blanco $\{Z_t\}$ tiene *media cero*.

Modo de verificarlo. Calcular la media aritmética y desviación estándar de los residuos observados

$$m(\hat{Z}_t) = \sum_{t=1}^n \frac{\hat{Z}_t}{n}$$


$$\hat{\sigma}_Z = \sqrt{\frac{\sum_{t=1}^n \left(\hat{Z}_t - m(\hat{Z}_t)\right)^2}{n}}$$

con estos elementos se construye la prueba, al nivel de significancia α , sobre si la media del proceso de ruido blanco es cero o no. Si se rechaza la hipótesis nula de que es cero, implica que existe una parte determinista en $\{\hat{Z}_t\}$ que no se ha considerado en el modelo, por lo que se podría requerir la inclusión de una tendencia determinista, que se estime de manera conjunta con el resto de los parámetros. No obstante, antes de incluir una forma explícita para esta tendencia, podría pensarse en que sea necesaria una diferencia más en el modelo.

- El proceso de ruido blanco tiene *varianza constante*.

La manera común de verificar el cumplimiento de este supuesto, es graficar los residuos contra el tiempo para decidir de forma *visual*, si la varianza parece o no constante. Esta forma de verificación visual, podría parecer muy burda, pero la cuestión es que sólo gruesas desviaciones de este supuesto son las que realmente llegan a causar problemas en el modelo, i.e., el modelo es un poco *robusto* contra desviaciones de la varianza constante. Si este problema es fuerte, hay que aplicar una transformación a la serie para estabilizar la varianza.

Gráfica de residuos vs. tiempo: Verificando homoscedasticidad




- El proceso de ruido blanco tiene elementos *mutuamente independientes*

Ya que independencia implica no autocorrelación, se debe verificar que $\rho_Z = 0, \forall k \neq 0$. Esto puede verificarse calculando, en primera instancia, la FAC muestral de los residuos, $\{r_k(\hat{Z})\}$, que si la media es cero, está dada por

$$r_k(\hat{Z}) = \frac{\sum_{t=1}^{n-k} \hat{Z}_t \hat{Z}_{t-k}}{\sum_{t=1}^n \hat{Z}_t^2}, \quad k = 1, 2, \dots \text{ y}$$

$$\sqrt{\widehat{Var}(r_k(\hat{Z}))} \approx \frac{1}{\sqrt{n}}$$



Para determinar si la autocorrelación de los residuos es o no significativamente distinta de cero, a un nivel de significancia α , podemos utilizar el criterio desprendido de la correspondiente prueba de hipótesis. Declararemos que la k -ésima autocorrelación es distinta de cero, si

$$|r_k(\hat{Z})| \geq \frac{Z_{1-\alpha/2}}{\sqrt{n}}$$

Para realizar una prueba conjunta sobre la significancia de las primeras K correlaciones, se utiliza el estadístico Q de Liung-Box (1978)


$$Q = n(n+2) \frac{\sum_{k=1}^K r_k(\hat{Z})}{n} \stackrel{a}{\sim} \chi_{(K)}^2$$

Entonces, rechazamos la hipótesis de no correlación, a un nivel de significancia α , si $Q > \chi_{(K, 1-\alpha)}^2$. Si la hipótesis se rechaza, significa que las autocorrelaciones no corresponden a un proceso de ruido blanco, y es de suponer que correspondan a un proceso ARMA. Es recomendable realizar el correlograma o el correlograma parcial para identificar el proceso


ARMA de los residuos, que implicaría realizar cambios al modelo.

- El proceso de ruido blanco tiene distribución normal


Una forma común de verificar este supuesto, no sólo en series de tiempo, sino en muchas otras áreas estadísticas, es mediante la gráfica conocida como *q-q plot*, que grafica los residuos ordenados, contra el valor esperado de las estadísticas de orden de una distribución normal. Si los residuos del modelo realmente son normales, entonces deben ser muy similares al correspondiente valor esperado de su estadística de orden normal, por lo que se debe observar una línea recta a 45° , que pase por el origen de coordenadas. Una manera de complementar la gráfica q-q plot, es mediante el histograma de los residuos, que debiera presentar la forma típica de una normal. Otra gráfica, propia de esta metodología, para comprobar lo adecuado de este supuesto, es graficar los *residuos estandarizados* contra el tiempo y dibujar las líneas horizontales en -2 y 2. Hay que recordar que fuera de estas líneas se pueden observar, a lo más, un 5 % de estos residuos.



Gráfica: QQ-norm residuos



- Detección de observaciones atípicas. Una gráfica de los residuos contra el tiempo, debe permitir observar si existen observaciones atípicas. Si los residuos están por fuera de las bandas formadas por los valores de -3 y 3, implicaría que, o el residuo corresponde a un evento cuya probabilidad de ocurrencia es muy baja (0.02), o que no fue generada por el proceso del resto de las observaciones. La forma de tratar estas observaciones implica hacer una investigación sobre la naturaleza de esta observación. Por ejemplo, su valor aparentemente anormal, podría deberse a un cambio estructural en el comportamiento de la serie, causado, tal vez, por una *intervención*. Otra posibilidad es que se deba a un simple error de codificación. En este caso lo que procede es corregir el error y ajustar nuevamente el modelo.



- El modelo es *admisible*. Se verifica de acuerdo a las condiciones de estacionariedad e invertibilidad correspondientes a los polinomios característicos de los operadores de retraso.
- *Estabilidad* en los parámetros. Usualmente la inestabilidad en los parámetros es causada por la *redundancia* de los mismos. Hay que prestar especial atención sobre aquellos parámetros que tengan correlaciones altas entre ellos, ya sea positivas o negativas. Una manera de enfentrar este problema es eliminar alguno de los parámetros que presente una alta correlación con otro(s).

Pronósticos con series de tiempo

Una vez que hemos propuesto, ajustado y verificado un modelo, la siguiente etapa consiste en hacer *uso del modelo*, para lograr los fines para los que fue construido. Uno de los objetivos más comunes es el de realizar *pronósticos*, que no es otra cosa más que estimar los valores W_{t+h} , $h = 1, 2, \dots$ a partir de los valores observados $\mathbf{W} = \{W_1, W_2, \dots, W_t\}$. Es obvio que debemos hacer un pronóstico que sea, en algún sentido, óptimo. El criterio que usaremos para lograrlo será el del *error cuadrático medio mínimo*, es decir, si denotamos $\hat{W}_t(h)$, como el valor pronosticado por el modelo para W_{t+h} , entonces deberá de cumplir la condición de

$$\mathbb{E} \left[W_{t+h} - \hat{W}_t(h) \right]^2 = \min_{\tilde{W}_t(h)} \mathbb{E} \left[W_{t+h} - \tilde{W}_t(h) \right]^2$$

donde $\mathbb{E}$ denota *la esperanza condicional*, dada toda la información (los valores de la serie) hasta el momento t , es decir

$$\mathbb{E} \left[W_{t+h} - \hat{W}_t(h) \right]^2 = \mathbb{E} \left\{ \left[W_{t+h} - \tilde{W}_t(h) \right]^2 \middle| W_t, W_{t-1}, \dots \right\}$$

Planteamiento formal

Error cuadrático medio mínimo de predicción (Minimum Mean Square Error Prediction)

Supongamos que y_t es un proceso estocástico estacionario con $\mathbb{E}(y_t) = 0$. Estamos interesados en predecir los valores de este proceso para varios periodos en el futuro, basándonos en su historia observada. Esta historia está contenida en el llamado *conjunto de información o conjunto de datos*. En la práctica, este conjunto es siempre finito $\{y_t, y_{t-1}, \dots, y_{t-p}\}$, que representa el pasado reciente del proceso. No obstante, en el desarrollo de la teoría de predicción, es usual considerarlo infinito $\{y_t, y_{t-1}, \dots, y_{t-p}, \dots\}$ representando el pasado completo.

Denotemos por $\hat{y}_{t+h}$ a la predicción de y_{t+h} , que implica que se hace el pronóstico h periodos adelante. El criterio usual para realizar la predicción, $\hat{y}$, de una variable aleatoria, X , es su error cuadrático medio, definido como

$$\mathbb{E} \{(y - \hat{y})^2\}$$

Si toda la información disponible sobre y está contenida en su distribución marginal, entonces el *merror cuadrático medio mínimo de predicción* es simplemente el valor esperado de y , $\mathbb{E}(y)$. Sin embargo, si está estadísticamente relacionado con otra variable aleatoria, x , cuyo valor pueda observarse, y si se conoce la función de distribución conjunta de x y y , entonces este error cuadrático medio mínimo de predicción de y , es la esperanza condicional, $\mathbb{E}(y|x)$. Enunciemos formalmente esta proposición.

• Sea $\hat{y} = \hat{y}(x)$ la esperanza condicional de y dado x , que podemos expresarla también como $\hat{y} = \mathbb{E}(y|x)$. Entonces, $\mathbb{E} \{(y - \hat{y})^2\} \leq \mathbb{E} \{(y - \pi)^2\}$, con $\pi = \pi(x)$ cualquier otra función de x .

Demostración

Consideremos la siguiente expresión

$$\begin{aligned} \mathbb{E} \{(y - \pi)^2\} &= \mathbb{E} [\{(y - \hat{y}) + (\hat{y} - \pi)\}^2] \\ &= \mathbb{E} \{(y - \hat{y})^2\} + 2\mathbb{E} \{(y - \hat{y})(\hat{y} - \pi)\} + \mathbb{E} \{(\hat{y} - \pi)^2\} \end{aligned}$$

el segundo término de la expresión es

$$\begin{aligned} \mathbb{E} \{(y - \hat{y})(\hat{y} - \pi)\} &= \int_x \int_y (y - \hat{y})(\hat{y} - \pi) f(x, y) \partial x \partial y \\ &= \int_x \left\{ \int_y (y - \hat{y}) f(y|x) \partial y \right\} (\hat{y} - \pi) f(x) \partial x \\ &= 0 \end{aligned}$$

la segunda igualdad de esta expresión proviene del hecho conocido que $f(x, y) = f(y|x)f(x)$.

Mientras que la igualdad final se desprende del hecho que

$$\begin{aligned} \int_y (y - \hat{y}) f(y|x) \partial y &= \int_y y f(y|x) \partial y - \int_y \hat{y} f(y|x) \partial y = \mathbb{E}(y|x) - \int_y \hat{y} f(y|x) \partial y \\ &= \mathbb{E}(y|x) - \mathbb{E}(y|x) = 0 \end{aligned}$$

Por lo tanto, concluimos que

$$\mathbb{E} \{ (y - \pi)^2 \} \geq \mathbb{E} \{ (y - \hat{y})^2 \} + \mathbb{E} \{ (y - \pi)^2 \} \geq \mathbb{E} \{ (y - \hat{y})^2 \}$$

que demuestra la proposición.

Algunas observaciones

La definición de esperanza condicional implica que

$$\begin{aligned} \mathbb{E}(xy) &= \int_x \int_y xy f(x, y) \partial x \partial y \\ &= \int_x x \left\{ \int_y y f(x, y) \partial y \right\} \partial x \\ &= \mathbb{E}(x\hat{y}) \end{aligned}$$

Si reescribimos la ecuación $\mathbb{E}(xy) = \mathbb{E}(x\hat{y})$ como

$$\mathbb{E} \{ x(y - \hat{y}) \} = 0$$

que puede verse como una condición de ortogonalidad. Esta condición implica que el error de predicción, $(y - \hat{y})$, no está correlacionado con x . Este resultado es intuitivamente deseable, porque, si el error estuviera correlacionado con x , no usaríamos la información de x de manera eficiente en la construcción de $\hat{y}$.

- La proposición que demostramos puede generalizarse para el caso donde, en lugar de un escalar, x sea un vector, $x = [x_1, x_2, \dots, x_p]'$. Esta generalización indica que el mínimo error cuadrático medio de predicción de y_{t+h} dada la información $\{y_t, y_{t-1}, \dots, y_{t-p}\}$ es la esperanza condicional $\mathbb{E}(y_{t+h} | y_t, y_{t-1}, \dots, y_{t-p})$.

- Para calcular esta esperanza condicional de y_{t+h} dada $\{y_t, y_{t-1}, \dots, y_{t-p}\}$, necesitamos conocer la forma funcional de la función de densidad conjunta de todas estas variables. A falta de un conocimiento preciso de esta densidad conjunta, debemos suponer que la distribución es normal. En cuyo caso se tiene que la esperanza condicional de y_{t+h} es una función lineal de

$\{y_t, y_{t-1}, \dots, y_{t-p}\}$, por lo que, el problema de predecir y_{t+h} se convierte en una formulación de un modelo de regresión lineal. Si no deseamos suponer una distribución normal para esta densidad conjunta, podemos, no obstante, basar la predicción de y mediante una función lineal de $\{y_t, y_{t-1}, \dots, y_{t-p}\}$. En este caso, el criterio del *error cuadrático medio mínimo de predicción lineal* se satisface definiendo

$$\hat{y}_{t+h} = \phi_1 y_t + \phi_2 y_{t-1} + \dots + \phi_{p+1} y_{t-p}$$

entonces, debemos encontrar los valores $\phi_1, \phi_2, \dots, \phi_{p+1}$ que minimicen

$$\begin{aligned} \mathbb{E} \{ (y_{t+h} - \hat{y}_{t+h})^2 \} &= \mathbb{E} \left\{ \left(y_{t+h} - \sum_{j=1}^{p+1} \phi_j y_{t-j+1} \right)^2 \right\} \\ &= \gamma_0 - 2 \sum_j \phi_j \gamma_{h+j-1} + \sum_i \sum_j \phi_i \phi_j \gamma_{i-j} \end{aligned}$$

donde $\gamma_{i-j} = \mathbb{E}(Z_{t-i} Z_{t-j})$ o, equivalentemente, $\gamma_{i-j} = \mathbb{E}(y_{t-i} y_{t-j})$. Este es un problema de regresión lineal de mínimos cuadrados, que genera un conjunto de $p+1$ condiciones ortogonales descritas como las ecuaciones normales

$$\begin{aligned} \mathbb{E} \{ (y_{t+h} - \hat{y}_{t+h}) y_{t-j+1} \} &= \gamma_{h+j-1} - \sum_{i=1}^p \phi_i \gamma_{i-j} \\ &= 0 \quad j = 1, 2, \dots, p+1 \end{aligned}$$

en términos matriciales

$$\begin{bmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_p \\ \gamma_1 & \gamma_2 & \cdots & \gamma_{p-1} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_p & \gamma_{p-1} & \cdots & \gamma_0 \end{bmatrix} \begin{bmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_{p+1} \end{bmatrix} = \begin{bmatrix} \gamma_h \\ \gamma_{h+1} \\ \vdots \\ \gamma_{h+p} \end{bmatrix}$$

Para la predicción únicamente de un periodo adelante, estas son las ecuaciones de *Yule-Walker*.

En el caso de un predictor óptimo que combina valores anteriores de la serie, se sigue, por el principio de ortogonalidad, que los errores de predicción no están correlacionados con las predicciones previas.

Un resultado de este tipo es familiar para los economistas en relación a la llamada *hipótesis de eficiencia del mercado*. Un mercado financiero es eficiente si los precios de los activos negociados constituyen previsiones óptimas de sus rendimientos futuros descontados, que consisten en pagos de intereses y dividendos y las ganancias de capital.

De acuerdo con la hipótesis, los cambios en los precios de los activos estarán correlacionados con los anteriores o actuales niveles de precios, lo que quiere decir que los precios de los activos siguen caminatas aleatorias. Por otra parte, no debería ser posible que alguien valorando sólo la historia pasada de precios de los activos, pueda cosechar una ganancia especulativa de manera sistemática y regular.

Pronósticos para series estacionarias

Supongamos que $\{W_t\}$ es una serie de tiempo estacionaria con media cero, que se obtuvo a partir de una serie original $\{X_t\}$ a través de la relación $W_t = \nabla^d T(X_t)$, para algún valor d y una cierta transformación, T . Supongamos además que W_t admite la representación $W_t = \psi(B)Z_t$, para la que existe un modelo **ARMA** equivalente, modelo que deseamos utilizar para realizar pronósticos de la serie. En particular si, a partir del origen $\mathbf{t}$, se desea pronosticar a la observación W_{t+h} , que se obtenga como combinación lineal de los valores de la serie $\{W_t\}$, y, en consecuencia, de los errores $\{Z_t\}$, será denotado por $\tilde{W}(h)$, mientras que el pronóstico óptimo se denotará como $\hat{W}(h)$.

El criterio que se utilizará para determinar la condición de optimalidad del pronóstico será, por supuesto, el *error cuadrático medio mínimo de predicción*, es decir, como ya vimos, $\hat{W}(h)$, debe satisfacer la condición

$$\mathbb{E} \left[W_{t+h} - \hat{W}_t(h) \right]^2 = \min_{\tilde{W}_t(h)} \mathbb{E} \left[W_{t+h} - \tilde{W}_t(h) \right]^2$$

donde $\mathbb{E}$ denota *la esperanza condicional*, dada toda la información (los valores de la serie) hasta el momento t , es decir

$$\mathbb{E} \left[W_{t+h} - \hat{W}_t(h) \right]^2 = \mathbb{E} \left\{ \left[W_{t+h} - \tilde{W}_t(h) \right]^2 \middle| X_t, X_{t-1}, \dots \right\}$$

Demostramos que $\tilde{W}(h)$, y por consiguiente también $\hat{W}(h)$, deben ser combinaciones lineales. Es decir, deben ser de la forma

$$\tilde{W}(h) = \gamma_h Z_t + \gamma_{h+1} Z_{t-1} + \dots = \sum_{j=h}^{\infty} \gamma_j Z_{t+h-j}$$

el problema de obtener $\hat{W}(h)$ se reduce a encontrar los valores $\gamma_h, \gamma_{h+1}, \dots$ de manera que se cumpla la condición de optimabilidad.

Para lograr este fin, escribamos la observación W_{t+h} de la siguiente manera

$$\begin{aligned}
W_{t+h} &= - \sum_{j=0}^{\infty} \psi_j Z_{t+h-j} \\
&= - \sum_{j=0}^{h-1} \psi_j Z_{t+h-j} - \sum_{j=h}^{\infty} \psi_j Z_{t+h-j}, \text{ con } \psi_0 \equiv -1
\end{aligned}$$

donde la primera suma corresponde a la *información desconocida* al tiempo t (porque está constituida por las observaciones desde $t+1$ hasta $t+h$), mientras que la segunda suma corresponde a la información conocida al tiempo t (desde $-\infty$ hasta t).

De esta última expresión y de la de $\tilde{W}(h)$, tenemos

$$W_{t+h} - \tilde{W}(h) = - \sum_{j=0}^{h-1} \psi_j Z_{t+h-j} - \sum_{j=h}^{\infty} (\psi_j + \gamma_j) Z_{t+h-j}$$

y, dado que $\mathbb{E}(Z_{t+i}Z_{t+j}) = 0$, $\forall i \neq j$, se tiene que

$$\mathbb{E} \left\{ \left[W_{t+h} - \tilde{W}(h) \right]^2 \right\} = \sum_{j=0}^{h-1} \psi_j^2 \sigma_Z^2 + \sum_{j=h}^{\infty} (\psi_j + \gamma_j)^2 \sigma_Z^2$$

el mínimo de esta expresión se obtiene cuando $\gamma_j = -\psi_j$, para $j = h, h+1, \dots$, y esta selección de valores de γ_j da como resultado que

$$\mathbb{E} \left\{ \left[W_{t+h} - \tilde{W}(h) \right]^2 \right\} = \sum_{j=0}^{h-1} \psi_j^2 \sigma_Z^2$$

con $\tilde{W}(h)$ dado por

$$\tilde{W}(h) = -\psi_h Z_t - \psi_{h+1} Z_{t-1} + \dots = - \sum_{j=h}^{\infty} \psi_j Z_{t+h-j}$$

Observemos que, dada la definición de esperanza condicional, se tiene que

$$\mathbb{E}(Z_{t+h-j}) = \begin{cases} Z_{t+h-j} & \text{si } j \geq h \\ 0 & \text{si } j < h \end{cases} \quad (1)$$

de donde se obtiene que

$$\begin{aligned} \mathbb{E}(W_{t+h}) &= -\mathbb{E}\left(\sum_{j=0}^{h-1} \psi_j Z_{t+h-j}\right) - \mathbb{E}\left(\sum_{j=h}^{\infty} \psi_j Z_{t+h-j}\right) \\ &= -\sum_{j=h}^{\infty} \psi_j Z_{t+h-j} \end{aligned}$$

que, al compar esta expresión con la del óptimo $\hat{W}(h)$, se encuentra que $\mathbb{E}(W_{t+h})$ **proporciona el pronóstico con error cuadrático medio mínimo**, en otras palabras

$$\hat{W}(h) = \mathbb{E}(W_{t+h})$$

Error de pronóstico

Una vez que se ha encontrado la forma de calcular de manera óptima la predicción en la una serie de tiempo, es necesario calcular su *error de pronóstico* y ver algunas de sus características. Primeramente, el error de pronóstico está dado por

$$\begin{aligned} e_t(h) &= W_{t+h} - \hat{W}_{t+h} \\ &= - \sum_{j=0}^{h-1} \psi_j Z_{t+h-j} \end{aligned}$$

que implica

$$\mathbb{E}(e_t(h)) = 0 \quad y \quad \mathbb{V}(e_t(h)) = \sum_{j=0}^{h-1} \psi_j^2 \sigma_Z^2$$

de la expresión de la derecha se desprende que $\hat{W}(h)$ es un estimador insesgado de W_{t+h} . Además se tiene que

$$\mathbb{V}(e_t(h)) - \mathbb{V}(e_t(h-1)) = \sum_{j=0}^{h-1} \psi_j^2 \sigma_Z^2 - \sum_{j=0}^{h-2} \psi_j^2 \sigma_Z^2 = \psi_{h-1}^2 \sigma_Z^2 \geq 0, \quad \text{si } h \geq 1$$

de aquí se deduce que al hacer un pronóstico óptimo, mientras más alejado del tiempo actual, t , se desee hacerlo (h grande) mayor será la varianza del mismo, y menor su precisión.

Si tomamos $h=1$ en la expresión del error de pronóstico, obtenemos

$$e_t(1) = W_{t+1} - \hat{W}_t(1) = Z_{t+1} \quad (2)$$

que muestra que los errores del pronóstico un periodo hacia adelante no están correlacionados. En general, los errores de pronóstico están correlacionados para $h \geq 2$ ya que, como se muestra en su expresión, la serie $\{e_t(h)\}$ con h fijo, sigue un proceso $MA(h-1)$.

Recordemos que deseamos realizar pronósticos de la serie $\{W_t\}$, considerando que conocemos el modelo $ARMA(p,q)$ subyacente

$$\phi(\mathbf{B}) W_t = \theta(\mathbf{B}) Z_t$$

entonces, tenemos que

$$\begin{aligned}\tilde{W}(h) &= \mathbb{E}(W_{t+h}) \\ &= \mathbb{E}(\phi_1 W_{t+h-1} + \cdots + \phi_p W_{t+h-p} + Z_{t+h} - \theta_1 Z_{t+h-1} - \cdots - \theta_q Z_{t+h-q}) \\ &= \phi_1 \mathbb{E}(W_{t+h-1}) + \cdots + \phi_p \mathbb{E}(W_{t+h-p}) + \mathbb{E}(Z_{t+h}) - \theta_1 \mathbb{E}(Z_{t+h-1}) - \cdots - \theta_q \mathbb{E}(Z_{t+h-q})\end{aligned}$$

sabemos que

$$\mathbb{E}(W_{t+h-j}) = \begin{cases} W_{t+h-j} & \text{si } j \geq h \\ \hat{W}(h-j) & \text{si } j < h \end{cases}$$

y haciendo uso de (1) y (2), se obtiene además que

$$\mathbb{E}(Z_{t+h-j}) = \begin{cases} W_{t+h-j} - \hat{W}_{t+h-j-1}(1) & \text{si } j \geq h \\ 0 & \text{si } j < h \end{cases}$$

esta expresión es muy importante y necesaria ya que, en contraste a (1), en la que aparecen los errores aleatorios Z_{t+h-j} *no observables*, aquí aparecen los valores de la serie y sus pronósticos, que sí son observables.

Ejemplo

Veamos un ejemplo para ilustrar esta última parte.

Supongase que W_t es el proceso ARMA(1,1) dado por

$$\begin{aligned}(1 - 0.6\mathbf{B}) W_t &= (1 + 0.2\mathbf{B}) Z_t \\ W_t &= 0.6W_{t-1} + Z_t + 0.2Z_{t-1}\end{aligned}$$

por lo que los pronósticos $\hat{W}_t(h)$ se calculan de la siguiente manera

$$\begin{aligned}
\hat{W}_t(1) &= \mathbb{E}(W_{t+1}) \\
&= 0.6\mathbb{E}(W_t) + \mathbb{E}(Z_{t+1}) + 0.2\mathbb{E}(Z_t) \\
&= 0.6W_t + 0.2 \left[W_t - \hat{W}_{t-1}(1) \right]
\end{aligned}$$

$$\begin{aligned}
\hat{W}_t(2) &= 0.6\mathbb{E}(W_{t+1}) + \mathbb{E}(Z_{t+2}) + 0.2\mathbb{E}(Z_{t+1}) \\
&= 0.6\hat{W}_t(1)
\end{aligned}$$

y, en general se tiene

$$\hat{W}_t(h) = 0.6\hat{W}_t(h-1), \quad h \geq 2$$

es decir, el cálculo de los pronósticos requiere un proceso recursivo.

Obsérvese que $\hat{W}_t(1)$ involucra el pronóstico de $\hat{W}_{t-1}(1)$ que, a su vez, requiere a $\hat{W}_{t-2}(1)$, ya que

$$\hat{W}_{t-1}(1) = 0.6W_{t-1} + 0.2 \left[W_{t-1} - \hat{W}_{t-2}(1) \right]$$

y así sucesivamente hasta llegar a

$$\hat{W}_1(1) = 0.6W_1 + 0.2 \left[W_1 - \hat{W}_0(1) \right]$$

y, como no existe información para calcular $\hat{W}_0(1)$, se supone $\hat{W}_0(1) = W_1$, es decir, se hace $Z_1 = 0$. Entonces, para obtener los pronósticos $\hat{W}_t(h)$, hay que calcular los valores

$$\begin{aligned}
\hat{W}_1(1) &= 0.6W_1 \\
\hat{W}_2(1) &= 0.8W_2 - 0.2\hat{W}_1(1) \\
&\vdots \\
\hat{W}_t(1) &= 0.8W_t - 0.2\hat{W}_{t-1}(1)
\end{aligned}$$

Pronósticos para el modelo de medias móviles (MA)

Veamos la manera en que se realizan los pronósticos para un modelo $MA(q)$ que es un caso particular de un modelo ARMA. Escribamos este modelo en la forma

$$W_t = Z_t - \sum_{j=1}^q \theta_j Z_{t-j}$$

Entonces, W_{t+h} se puede escribir como

$$W_{t+h} = Z_{t+h} - \sum_{j=1}^q \theta_j Z_{t+h-j}$$

Entonces, dada la forma de nuestro predictor óptimo $\hat{W}_t(h)$, se tiene que para este modelo

$$\hat{W}_t(h) = - \sum_{j=h}^q \theta_j Z_{t+h-j}$$

y las Z'_t s involucradas, deben calcularse de forma recursiva como se mostró en el ejemplo. Ya que supusimos que el modelo ARMA general se podía escribir como $W_t = \psi(B) Z_t$ y como

también $\psi(B)$ se puede escribir $\psi(B) = \sum_{i=0}^{\infty} \chi_i \mathbf{B}^i$, entonces tenemos que $\chi_0 = 1$ y $\chi_k = -\theta_k$,

$k=1,2,\dots,q$, y si sustituimos estos valores en la fórmula general de la varianza del pronóstico de un ARMA, ya presentada, tenemos

$$\mathbb{V}(e(h)) = \sigma_Z^2 \left(1 - \sum_{j=1}^{h-1} \theta_j^2 \right)$$

Pronósticos para el modelo auto regresivo (AR)

Pronósticos AR(1)

Consideremos inicialmente el modelo AR(1), que tiene la forma

$$W_t = \phi W_{t-1} + Z_t$$

Siguiendo la misma lógica anterior, calculemos el pronóstico óptimo un periodo adelante, $h = 1$. Primeramente

$$W_{t+1} = \phi W_t + Z_{t+1}$$

Entonces, el pronóstico para un periodo adelante se calcula como

$$\begin{aligned}\hat{W}(1) = \mathbb{E}(W_{t+1}) &= \phi \mathbb{E}(W_t) + \mathbb{E}(Z_{t+1}) \\ &= \phi W_t\end{aligned}$$

Para dos periodos adelante, $h = 2$, tenemos

$$W_{t+2} = \phi W_{t+1} + Z_{t+2}$$

con pronóstico

$$\begin{aligned}\hat{W}(2) = \mathbb{E}(W_{t+2}) &= \phi \mathbb{E}(W_{t+1}) + \mathbb{E}(Z_{t+2}) \\ &= \phi \mathbb{E}(W_{t+1}) \\ &= \phi \hat{W}(1) \\ &= \phi^2 W_t\end{aligned}$$

entonces, en general, para el pronóstico $h \geq 1$ periodos adelante, tenemos que

$$\begin{aligned}
\hat{W}(h) = \mathbb{E}(W_{t+h}) &= \phi \mathbb{E}(W_{t+h-1}) + \mathbb{E}(Z_{t+h}) \\
&= \phi \mathbb{E}(W_{t+h-1}) \\
&= \phi \hat{W}(t+h-1) \\
&= \phi^h W_t
\end{aligned}$$

para este caso general el error de pronóstico es

$$\begin{aligned}
e(h) &= W_{t+h} - \hat{W}(h) \\
&= \phi W_{t+h-1} + Z_{t+h} - \phi^h W_t \\
&= \phi(\phi W_{t+h-2} + Z_{t+h-1}) + Z_{t+h} - \phi^h W_t \\
&\vdots \\
&= \phi^h W_t + \phi^{h-1} Z_{t+1} + \phi^{h-2} Z_{t+2} + \cdots + \phi Z_{t+h-1} + Z_{t+h} - \phi^h W_t \\
&= \phi^{h-1} Z_{t+1} + \phi^{h-2} Z_{t+2} + \cdots + \phi Z_{t+h-1} + Z_{t+h}
\end{aligned}$$

De donde se tiene que

$$\begin{aligned}
\mathbb{V}(e(h)) &= \mathbb{V}(\phi^{h-1} Z_{t+1} + \phi^{h-2} Z_{t+2} + \cdots + \phi Z_{t+h-1} + Z_{t+h}) \\
&= \sigma_Z^2 [1 + \phi^2 + \cdots + \phi^{2(h-2)} + \phi^{2(h-1)}] \\
&= \sigma_Z^2 \frac{1 - \phi^{2h}}{1 - \phi^2}
\end{aligned}$$

Pronósticos AR(p)

En este caso el modelo es

$$W_t = \phi_1 W_{t-1} + \phi_2 W_{t-2} + \cdots + \phi_p W_{t-p} + Z_t$$

Para realizar el pronóstico un periodo adelante ($h = 1$), tenemos, primeramente que

$$W_{t+1} = \phi_1 W_t + \phi_2 W_{t-1} + \cdots + \phi_p W_{t-p+1} + Z_{t+1}$$

Entonces

$$\begin{aligned}\hat{W}(1) = \mathbb{E}(W_{t+1}) &= \phi_1 \mathbb{E}(W_t) + \phi_2 \mathbb{E}(W_{t-1}) + \cdots + \phi_p \mathbb{E}(W_{t-p+1}) + \mathbb{E}(Z_{t+1}) \\ &= \phi_1 W_t + \phi_2 W_{t-1} + \cdots + \phi_p W_{t-p+1}\end{aligned}$$

con error de pronóstico

$$e(1) = W_{t+1} - \hat{W}(1) = Z_{t+1}$$

Consideremos ahora el pronóstico dos periodos adelante ($h = 2$) de este modelo. Primeramente

$$W_{t+2} = \phi_1 W_{t+1} + \phi_2 W_t + \cdots + \phi_p W_{t-p+2} + Z_{t+2}$$

y

$$\begin{aligned}\hat{W}(2) = \mathbb{E}(W_{t+2}) &= \phi_1 \mathbb{E}(W_{t+1}) + \phi_2 \mathbb{E}(W_t) + \cdots + \phi_p \mathbb{E}(W_{t-p+2}) + \mathbb{E}(Z_{t+2}) \\ &= \phi_1 \mathbb{E}(W_{t+1}) + \phi_2 W_t + \cdots + \phi_p (W_{t-p+2}) \\ &= \phi_1 \hat{W}(1) + \phi_2 W_t + \cdots + \phi_p (W_{t-p+2})\end{aligned}$$

en general, para el pronóstico $h \geq 1$ periodos adelante, tenemos que

$$W_{t+h} = \phi_1 W_{t+h-1} + \phi_2 W_{t+h-2} + \cdots + \phi_p W_{t+h-p} + Z_{t+h}$$

que, de manera totalmente semejante a las anteriores, da como pronóstico óptimo

$$\hat{W}(h) = \phi_1 \hat{W}(h-1) + \phi_2 \hat{W}(h-2) + \cdots + \phi_p \hat{W}(h-p)$$

con $\hat{W}(h-j) = W_{t+h-j}$ valores observados de la serie, si $j \geq h$.