

MODULO 4 CONTROL 1

Nombre: Andrés Padrón Quintana

1.- ¿Cuáles son los supuestos fundamentales del modelo de regresión lineal clásica (MCO)? Menciona al menos cuatro.

- Homocedasticidad (varianza constante)
- No Autocorrelación (covarianza igual a cero)
- Normalidad de los errores (el error se distribuye con media cero, varianza sigma cuadrada por la identidad)
- Linealidad de los parámetros
- Exogeneidad (esperanza del error es cero)
- Sin multicolinealidad (no hay combinación lineal exacta entre los regresores)

2.- Se ha ajustado un modelo de regresión lineal. El test de Durbin-Watson arrojó un valor de 1.1. ¿Qué indica este resultado? ¿Qué tipo de supuesto se evalúa con esta prueba?

El test de Durbin–Watson (DW) evalúa el supuesto de no autocorrelación (independencia) de los errores, en particular autocorrelación de primer orden.

- $DW \approx 2 \Rightarrow$ sin autocorrelación.
- $DW < 2 \Rightarrow$ autocorrelación positiva.
- $DW > 2 \Rightarrow$ autocorrelación negativa.

Como $1.1 < 2$, sugiere autocorrelación positiva en los errores.

3.- Describe cómo podrías evaluar la normalidad de los errores de un modelo de regresión. Menciona al menos dos métodos distintos y explica cómo se interpretan.

- Gráfico Q–Q (Quantile–Quantile) de residuales estandarizados. Ordenamos los residuales estandarizados $\hat{e}_i^*$ y los graficamos contra los cuantiles teóricos de una Normal(0,1).

Analizamos la gráfica:

- Puntos cerca de la línea → compatible con normalidad.
- Curvatura en S → colas más pesadas/ligeras que la normal.
- Desviaciones en extremos → colas no normales o outliers.
- Asimetría (puntos por encima en un extremo y por debajo en el otro) → no simetría de los errores.
- Pruebas formales sobre residuales (aplicadas a residuales estandarizados o studentizados)

Prueba Jarque–Bera (usamos sesgo y curtosis)

- H_0 : normalidad (sesgo $\approx$ 0, curtosis $\approx$ 3).
- Estadístico alto / p bajo → no normalidad (asimetría/colas pesadas).
- Histograma + densidad vs. campana normal
Trazamos histograma de $\hat{e}_i$ y superponemos densidad normal con misma media y varianza.
Si la forma aproximadamente simétrica y acampanada indica compatibilidad, picos/colas largas sugieren desviaciones.

4.-Un analista observa heterocedasticidad en su modelo pero decide no corregirla porque el valor de R^2 es alto. ¿Por qué este razonamiento es incorrecto? Explica las consecuencias de ignorar la heterocedasticidad.

- La R^2 no prueba supuestos. Solo mide ajuste in-sample, puede ser alto aunque los errores violen homocedasticidad.
- Con heterocedasticidad, los estimadores MCO siguen siendo insesgados/consistentes (si $E[\varepsilon | X] = 0$), pero no son eficientes (no BLUE) y, sobre todo, sus errores estándar habituales son incorrectos.

Si ignoramos esto puede haber:

- Inferencia engañosa: p-valores erróneos → puedes aceptar variables irrelevantes o eliminar variables útiles.
- Intervalos mal calibrados: IC demasiado estrechos o anchos.
- Ineficiencia: puede haber estimadores con menor varianza que MCO.

5.- ¿Qué es la multicolinealidad y por qué puede ser un problema en la regresión lineal?

La multicolinealidad ocurre cuando uno o varios regresores están altamente correlacionados entre sí (colinealidad alta) o cuando existe una combinación lineal casi exacta entre ellos (colinealidad casi perfecta).

Puedes ser un problema porque:

- Varianzas infladas de $\hat{\beta}$ → errores estándar grandes, IC muy anchos y pruebas t con baja potencia.
- Inestabilidad numérica: pequeños cambios en los datos producen grandes cambios en los coeficientes.
- Difícil interpretación parcial: separar el efecto de cada variable es poco fiable cuando entregan información casi duplicada.

6.- Tienes un modelo de regresión múltiple con las variables X1, X2 y X3. Notas que el estadístico VIF (Variance Inflation Factor) de X2 es 15. ¿Qué indica este valor y qué acciones podrías tomar?

$$VIF_2 = \frac{1}{1-R_2^2} \Rightarrow R_2^2 = 1 - \frac{1}{15} \approx 0.933.$$

X2 está ~93.3% explicada por (X1, X3) ⇒ fuerte multicolinealidad.

Algunas acciones podrían ser:

Diagnosticar: revisar VIF de las demás, correlaciones y número de condición.

Podemos eliminar/combinar variables redundantes, elegir la más interpretable, considerar centrar/estandarizar, recolectar más datos si es posible.

Podemos usar ridge (reduce varianza), lasso (selección) o PCA/PLS para reemplazar variables colineales por componentes ortogonales.

Regla práctica: $VIF > 10$ es preocupante por lo que si el valor es 15 se requiere acción antes de interpretar $\hat{\beta}_2$.

7.-Explica cómo puedes evaluar el supuesto de independencia de los errores de manera gráfica.

Residuos vs. índice temporal (o de observación)

Trazamos $\hat{e}_t$ contra t y revisamos:

- Independencia: Vemos una nube ruidosa sin tendencias, ciclos ni rachas largas del mismo signo.

Correlograma ACF de residuales

- Graficamos autocorrelaciones $\rho(k)$ para rezagos k .
- Independencia: Si casi todas las barras caen dentro de las bandas de significancia.

Lag plot de residuales ($\hat{e}_t$ vs. $\hat{e}_{t-1}$)

- Independencia: Si vemos una nube circular sin patrón.

8.- Un gráfico Q-Q plot de los residuos muestra una fuerte desviación en las colas respecto a la línea diagonal. ¿Qué significa esto y qué implicaciones tiene para los supuestos del modelo?

Indica que los residuales no siguen una distribución Normal:

- Si las colas del Q-Q están por encima de la línea en ambos extremos → colas pesadas (más outliers de lo esperado);
- Si están por debajo → colas ligeras;
- Asimetrías en un solo extremo → sesgo en los errores.

Implicaciones para los supuestos del modelo:

- Se viola la normalidad de los errores

- Los p-values e intervalos basados en normalidad pueden estar mal calibrados, sobre todo en muestras pequeñas.
- Mayor sensibilidad a outliers

9.- Supón que estás trabajando con un conjunto de datos donde muchas variables predictoras están fuertemente correlacionadas entre sí. ¿Qué alternativas existen a la regresión lineal tradicional para abordar este problema de multicolinealidad? Nombra y explica al menos una.

Como lo vimos en el módulo:

- Ridge (L2)
Agrega penalización $\lambda \sum \beta_j^2$. No hace pero los coeficientes, pero encoge los muy correlacionados y reduce la varianza de $\hat{\beta}$. Es muy útil cuando todas las variables aportan al modelo y queremos estabilizar estimaciones. Requiere estandarizar X y elegir λ por Cross-Validation.
- Lasso (L1)
Penaliza $\lambda \sum |\beta_j|$; además de encoger, puede poner en cero algunos β_j , por lo que la selección de variables automática. Maneja colinealidad reteniendo típicamente uno de los regresores altamente correlacionados. También se sintoniza λ por CV.
- Elastic Net (L1+L2)
Combinamos Ridge y Lasso. Funciona muy bien cuando hay grupos de variables altamente correlacionadas: tiende a seleccionar el grupo completo con pesos estables.

10.- Tienes dos modelos de regresión Lineal:

Modelo 1: 5 variables y R^2 de .75

Modelo 2: 15 variables y R^2 de .79

¿En que escenario escogerías el Modelo 1 y en que escenario escogerías el Modelo 2?

Elegiría el Modelo 1 cuando:

- La prioridad es interpretabilidad y parsimonia (resumen del modelo y simple)
- En validación/CV no mejora de forma exagerada frente al Modelo 2 (misma MAE/RMSE, misma PR).
- R^2_{adj} y/o BIC favorecen al modelo simple.
- Hay n moderado/pequeño o riesgo de sobreajuste/multicolinealidad con 15 variables.

Elegiría el Modelo 2 cuando:

- La meta es predicción y, en prueba/CV, mejora sustancialmente (p. ej., $\downarrow$ RMSE, $\uparrow R^2$ out-of-sample) respecto al Modelo 1.
- R^2_{adj} y AIC lo favorecen y no hay señales fuertes de multicolinealidad/inestabilidad.
- El aumento de complejidad está justificado por el negocio (variables adicionales aportan señal útil).
- Se controla el riesgo con regularización (ridge/lasso) o selección por CV.

Enviar solución a sergio.chavez.molotla@itam.mx

Fecha de entrega: 23 de Noviembre 2025